## 7 PARALELIZEM NA NIVOJU UKAZOV

BRANKO ŠTER

PO KNJIGI - DUŠAN KODEK: ARHITEKTURA IN ORGANIZACIJA RAČUNALNIŠKIH SISTEMOV

## Z doslej obravnavanim načinom gradnje CPE je težko doseči CPI < 4

· zaporedno izvrševanje

Število ukazov na sekundo je

$$IPS = f_{CPE} / CPI$$

IPS ... Instructions Per Second

 $f_{\mathit{CPE}}$  ... frekvenca ure

CPI ... Clocks Per Instruction

#### IPS lahko povečamo:

- s povečanjem f<sub>CPE</sub> (hitrejši logični elementi)
- z drugačno zgradbo CPE, ki bi zmanjšala CPI (več logičnih elementov)

V 20 letih se hitrost elementov poveča  $\sim$  10x, št. elementov na čipu pa  $\sim$  1000x

o zato je druga varianta bolj perspektivna

PARALELIZEM NA NIVOJU UKAZO

Z uporabo večjega števila elementov skušamo zmanjšati *CPI* (in s tem povečati *IPS*)

• Skušamo doseči čimvečjo paralelnost (istočasnost) operacij

#### Ena možnost je paralelno programiranje

- o programer določi, kaj naj se izvaja paralelno
- dokaj komplicirano: potrebujemo izvorno kodo in znanje, kako to narediti
- večina uporabnikov se s tem ne želi ukvarjati

Enostavneje je izkoristiti **paralelizem na nivoju ukazov** (instruction-level parallelism, ILP)

Najpogostejši način je cevovod (pipeline)

PARALELIZEM NA NIVOJU UKAZOV

3

## Cevovod - splošno



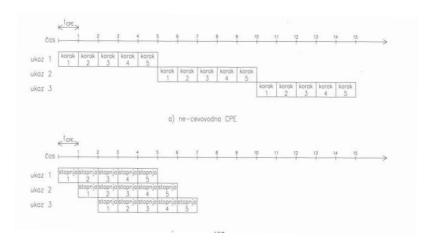
#### Cevovod (pipeline)

- Pri cevovodu se naenkrat izvršuje več ukazov tako, da se posamezni koraki izvrševanja prekrivajo
- · Podobno tekočemu traku pri proizvodnji
- Vsako podoperacijo opravi določen del cevovoda
  - stopnja cevovoda (pipeline stage) ali segment cevovoda
- Stopnje tvorijo nekakšno cev
  - ukazi vstopajo v cev, potujejo skoznjo in izstopajo na koncu cevi

PARALELIZEM NA NIVOJU UKAZO

#### Primer: ne-cevovodna CPE in cevovodna CPE

 v drugem primeru se izvrši 5x več ukazov (če zanemarimo začetno zakasnitev)



PARALELIZEM NA NIVOJU UKAZOV

Čas med dvema pomikoma je praviloma enak urini periodi  $t_{\mathit{CPE}}$ 

Perioda ne more biti krajše od časa, ki ga za izvršitev svoje podoperacije potrebuje najpočasnejša izmed stopenj cevovoda

- zato je dobro, če so podoperacije časovno uravnotežene
- pri idealno uravnoteženi cevovodni CPE z N stopnjami je zmogljivost N-krat večja kot pri ne-cevovodni CPE
  - hkrati se obdeluje N ukazov
  - o na izhodu iz cevovoda jih je zato N-krat več
  - CPI N-krat manjši
- resnični cevovodi pa nikoli niso idealno uravnoteženi, zato zmogljivost ni N-kratna

PARALELIZEM NA NIVOJU UKAZO

## Število izvršenih ukazov v danem času se poveča zaradi 2 vzrokov:

- 1. manjši CPI
  - čeprav je trajanje ukaza (latenca) enako ( $N^*t_{CPE}$ )
- 2. krajša  $t_{CPF}$ 
  - če uspemo narediti enostavne podoperacije
  - $t_{\text{CPE}} = t_{\text{shranjevanje}} + t_{\text{podoperacija}}$

 $t_{\text{shranjevanje}}$  ... čas shranjevanja rezultata podoperacije v registre

 $\circ$  z več stopnjami lahko zmanjšamo  $t_{
m podoperacija}$ ,  $t_{
m shranjevanje}$  pa ne

PARALELIZEM NA NIVOJU UKAZOV

7

#### Supercevovodni računalniki

- Intel Pentium 4
  - 20-stopenjski, kasneje 31-stopenjski cevovod
    - $\circ~$ želeli so doseči  $f_{\rm CPE}$  10GHz, a je bila poraba prevelika (problemi s hlajenjem, tj. odvajanjem toplote)
    - kasnejši CPU (npr. Core) imajo (le) 14-stopenjski cevovod

#### BTW: najvišja dosežena frekvenca je nekaj nad 8GHz (AMD)

 s pomočjo navijanja frekvence (overclocking), pa tudi polivanja čipa s tekočim dušikom





ARALELIZEM NA NIVOJU UKAZO

Zakaj se ne uporabljajo poljubno dolgi cevovodi?
• pač povečujemo N in višamo hitrost CPU ...



PARALELIZEM NA NIVOJU UKAZO\

9

## Cevovodne nevarnosti



Razlog so **cevovodne nevarnosti** (pipeline hazards), zaradi katerih se mora cevovod ustaviti in počakati, da nevarno mine

3 vrste cevovodnih nevarnosti:

- 1. Strukturne nevarnosti
  - kadar več stopenj cevovoda v neki urini periodi potrebuje isto enoto
- 2. Podatkovne nevarnosti
  - kadar ukaz potrebuje kot vhodni operand rezultat prejšnjega, še ne dokončanega ukaza
- 3. Kontrolne nevarnosti
  - možne pri skokih, klicih in drugih kontrolnih ukazih, ki spreminjajo vsebino PC

Zato zmogljivost z večanjem števila stopenj nekaj časa narašča, nato pa začne padati!

PARALELIZEM NA NIVOJU UKAZO

## Prednost cevovoda je, da ga je mogoče narediti tako, da je za programerja neviden

- arhitektura računalnika in programiranje ostane enako tudi z razvojem računalnika
  - starejši programi tečejo tudi na novejših računalnikih
- o pri drugih vrstah paralelnega procesiranja to pogosto ne velja
- · zadnji Intelov necevovodni procesor je bil 80386 (iz leta 1985)

PARALELIZEM NA NIVOJU UKAZOV

1

## Cevovodna podatkovna enota

Cevovodna realizacija je pri računalnikih RISC enostavnejša kot pri CISC o preprostejši ukazi

Cevovodno CPE si bomo ogledali na primeru računalnika HIP

5 korakov izvrševanja ukazov: 5 stopenj cevovoda

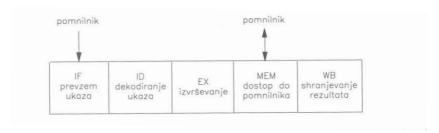
- 1. IF: prevzem ukaza in sprememba PC
- 2. ID: dekodiranje ukaza in dostop do registrov
- 3. EX: izvrševanje operacije
- 4. MEM: dostop do pomnilnika
- 5. WB: shranjevanje rezultata

Vsaka stopnja mora opraviti svoje delo v eni urini periodi

• prej so nekateri koraki potrebovali 2 periodi

PARALELIZEM NA NIVOJU UKAZO

# Petstopenjska cevovodna podatkovna enota procesorja HIP:



Včasih sta potrebna dva hkratna dostopa do pomnilnika

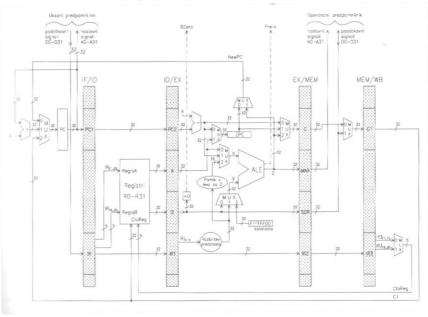
Cevovodni HIP ima zato 2 predpomnilnika:

- ukazni
- operandni

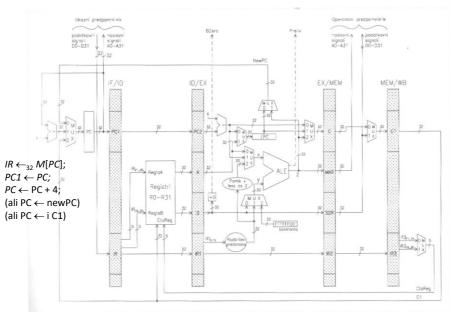
PARALELIZEM NA NIVOJU UKAZOV

1

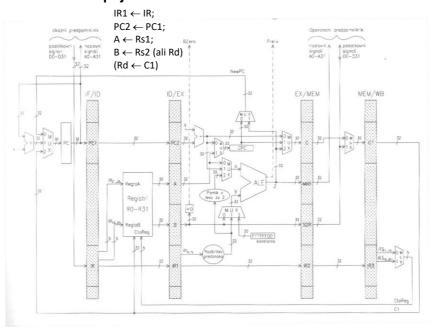
## Cevovodna podatkovna enota



#### 1. Stopnja IF

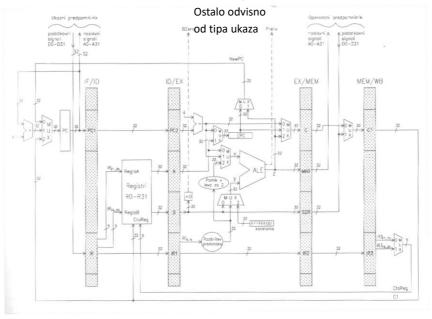


#### 2. Stopnja ID



#### 3. Stopnja EX

 $IR2 \leftarrow IR1;$ 



#### → Stopnja EX

- prehod v to stopnjo se imenuje izstavitev ukaza (instruction issue)
  - tukaj se ukaza več ne da na preprost način izničiti (v IF in ID ni problema)
- Delovanje stopnje EX je odvisno od vrste ukaza:

#### Ukazi za prenos podatkov

 $IR2 \leftarrow IR1$ 

 $\mathsf{SDR} \leftarrow \mathsf{B}$ 

 $\mathsf{MAR} \leftarrow \mathsf{A} + \mathsf{raz}(\mathsf{IR1}_{0..15})$ 

#### **ALE** ukazi

 $IR2 \leftarrow IR1$ 

 $SDR \leftarrow B$ 

 $C \leftarrow A \text{ op B (ali raz(IR1_{0..15}))}$ 

PARALELIZEM NA NIVOJU UKAZO

#### Klic in brezpogojni skok

$$\begin{split} & \text{IR2} \leftarrow \text{IR1} \\ & \text{C} \leftarrow \text{PC2} + 4 \\ & \text{NewPC} \leftarrow \text{A} + \text{raz}(\text{IR1}_{0..15}) \end{split}$$

#### Pogojni skoki

$$\begin{split} & \text{IR2} \leftarrow \text{IR1} \\ & \text{NewPC} \leftarrow \text{PC2} + 4 + \text{raz}(\text{IR1}_{0..15}) \end{split}$$

#### **TRAP**

$$\begin{split} & \text{IR2} \leftarrow \text{IR1} \\ & \text{EPC} \leftarrow \text{PC2} + 4 \\ & \text{MAR} \leftarrow \text{FFFFFF00} + 4 \text{xraz} (\text{IR1}_{0..15}) \\ & \text{I} \leftarrow 0 \end{split}$$

PARALELIZEM NA NIVOJU UKAZO

19

#### **RFE**

$$IR2 \leftarrow IR1$$

$$NewPC \leftarrow EPC$$

#### **MOVER in MOVRE**

$$IR2 \leftarrow IR1$$
  
 $C \leftarrow EPC (pri MOVER)$   
 $EPC \leftarrow A (pri MOVRE)$ 

#### El in DI

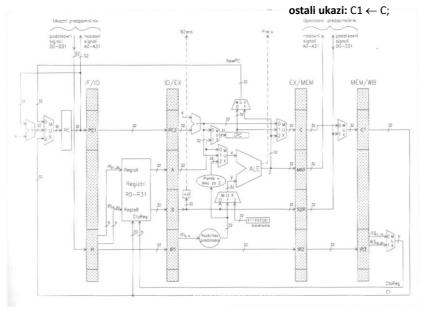
IR2 
$$\leftarrow$$
 IR1  
I  $\leftarrow$  1 (pri EI) ali I  $\leftarrow$  0 (pri DI)

PARALELIZEM NA NIVOJU UKAZO\

#### **4. Stopnja MEM** IR3 $\leftarrow$ IR2;

 $\textbf{load in TRAP: } C1 \leftarrow M[MAR]; (OPP)$ 

store:  $M[MAR] \leftarrow SDR$ ; (OPP)



#### → Stopnja MEM

#### load in TRAP

 $IR3 \leftarrow IR2; \quad C1 \leftarrow M[MAR];$ 

branje iz operandnega PP

store

 $IR3 \leftarrow IR2; \quad M[MAR] \leftarrow SDR;$ 

SDR se shrani v operandni PP

Ostali ukazi

 $IR3 \leftarrow IR2;$   $C1 \leftarrow C;$  (zaradi WB)

pri zgrešitvah se ustavijo vse stopnje cevovoda (čakanje na MemWait)

PARALELIZEM NA NIVOJU UKAZO

# S. Stopnja WB ALE ukazi, load, CALL, MOVER: President prodomolosis COperations predomolosis CALL, MOVER: Rd ← C1; TRAP: PC ← C1; PC → C1;

#### Idealen potek izvrševanja ukazov v cevovodu

	Urina perioda										
Št. ukaza	1	2	3	4	5	6	7	8	9	10	11
ukaz i	IF	ID	EX	ME	WB						
ukaz i+1		IF	ID	EX	ME	WB					
ukaz i+2			IF	ID	EX	ME	WB				
ukaz i+3				IF	ID	EX	ME	WB			
ukaz i+4					IF	ID	EX	ME	WB		
ukaz i+5						IF	ID	EX	ME	WB	
ukaz i+6							IF	ID	EX	ME	WB

ARALELIZEM NA NIVOJU UKAZOV

## Cevovodne nevarnosti

Ob pojavu nevarnosti se mora cevovod ustaviti in počakati, da nevarnost mine

#### Programsko odpravljanje cevovodnih nevarnosti

- pri prvih RISC (80. leta)
- vstavljanje ukazov NOP za ukaze, ki lahko povzročijo nevarnost
  - NOP ne spremeni stanja registrov
  - ekvivalentno čakanju eno urino periodo
  - o pri višjih programskih jezikih jih vstavlja kar prevajalnik
- 2 slabosti:
  - o potrebno je drugačno programiranje
  - upočasnjeno delovanje
- o ni več posebno aktualno

PARALELIZEM NA NIVOJI I I KAZOV

25

## Strukturne nevarnosti

- SN: kadar več stopenj cevovoda v neki urini periodi potrebuje isto enoto (reg., ALE, GP, PP)
- SN tudi na računalnikih, kjer nekateri ukazi trajajo več urinih period
  - Množenje, deljenje, FP operacije
- Izguba zaradi SN običajno bistveno manjša kot zaradi drugih nevarnosti
- Popolno odpravljanje SN je drago (večje število enot)
  - Na manjših računalnikih se pač dovoli, da do njih občasno pride
- Pri HIP do SN ne prihaja
  - Če PP ne bi bil razdeljen, bi lahko prihajalo (load, store)

PARALELIZEM NA NIVOJU UKAZO

#### Podatkovne nevarnosti

- PN (data hazard): kadar ukaz potrebuje kot vhodni operand rezultat še ne dokončanega ukaza
  - medsebojna odvisnost ukazov, ki so blizu skupaj
- Npr.

```
ADDI
         R20, R0, #0
                         R20 \leftarrow 0
SUB
         R3, R4, R5
                         R3 \leftarrow R4 - R5
ADD
         R1, R3, R6
                         R1 \leftarrow R3 + R6
         R2, R3, R7
AND
                         R2 \leftarrow R3 \wedge R7
XOR
                         R8 ← R3 ⊕ R9
         R8, R3, R9
OR
         R10, R3, R12 R10 ← R3 ∨ R12
```

PARALELIZEM NA NIVOJU UKAZOV

27

## Rešitev 1: Cevovodna zaklenitev (pipeline interlock)

- Stopnja ID se ustavi za 3 periode (zato se mora tudi IF, ker bi se sicer izgubil ukaz, ki je v njej). EX,MEM in WB morajo delovati naprej (sicer se vzrok za nevarnost ne bo odstranil).
- Vsaka stopnja, kjer lahko pride do napake, mora imeti vgrajeno logiko za cev. zaklenitev
- mehurček (bubble) je strojni ekvivalent operacije NOP
  - mehurček naredimo z "ukazom" NOP (32 ničel, ADDI ...)
  - v tem primeru ga "izvaja" stopnja EX
  - mehurček potuje od stopnje EX naprej
- Pri HIP lahko pride do PN le v stopnji ID
  - $^{\circ}$  prisotnost nevarnosti se ugotovi s primerjavo bitov IR $_{16..20}$  in IR $_{21..25}$  (Rs1, Rs2) z biti IRx $_{16..20}$  in IRx $_{21..25}$  (format 1, 2), x=1..3
  - to velja le za ukaze, ki shranjujejo v Rd (v stopnjah EX, MEM in WB)

PARALELIZEM NA NIVOJU UKAZO

	Urina perioda												
Ukaz	1	2	3	4	5	6	7	8	9	10	11	12	13
ADDI R20,R0,#0	IF	ID	EX	MEM	WB								
SUB R3,R4,R5		IF	ID	EX	MEM	WB							
ADD R1,R3,R6			IF	0	0	0	ID	EX	MEM	WB			
AND R2,R3,R7							IF	ID	EX	MEM	WB		
XOR R8,R3,R9								IF	ID	EX	MEM	WB	
OR R10,R3,R12									IF	ID	EX	MEM	WB

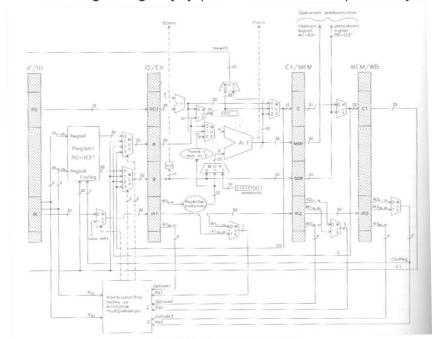
PARALELIZEM NA NIVOJU UKAZOV

29

# Rešitev 2: Premoščanje (bypassing, data forwarding)

- rezultat ukaza ADD iz EX prenesemo v ID in ustavljanje ni potrebno
- vendar premoščanje le iz EX v ID ni dovolj:
  - tudi AND in XOR rabita rezultat ukaza ADD (v R3 ga še ni, v EX pa ga ni več)
- logika za premoščanje mora omogočati prenos iz stopenj EX, MEM in WB v stopnjo ID
- PN se ugotavljajo s primerjavo Rs1 in Rs2 v stopnji ID z Rd, ki ga uporabljajo ukazi v stopnjah EX do WB (če gre za ukaze, ki pišejo v Rd)
- če PN ni mogoče odpraviti (pri HIP možno le pri load), logika ustavi IF, v ID pa vstavi mehurček v IR1

PARALELIZEM NA NIVOJU UKAZO



#### Cevovodna PE z logiko za ugotavljanje podatkovnih nevarnosti in premoščanjem

## Tako se bistveno zmanjša izguba zaradi PN, ni pa popolnoma odpravljena

- Včasih premoščanje ni možno, ker operanda ni v cevovodu
- Npr.

LW	R3, 56(R4)	$R3 \leftarrow_{32} M[56 + R4]$
SUB	R1, R3, R6	$R1 \leftarrow R3 - R6$
ADD	R2, R3, R7	$R2 \leftarrow R3 + R7$
XOR	R8, R3, R9	$R8 \leftarrow R3 \oplus R9$

- LW dobi operand šele v stopnji MEM
- Premoščanje v ID ni možno, ker operanda ni v CPE
- Čakanje je nujno (se pa da zmanjšati za eno periodo)
- Pri ADD pa čakanje ni potrebno (zaradi premoščanja iz WB)

PARALELIZEM NA NIVOJU UKAZO

#### Potek izvajanja ukazov pri premoščanju

		Urina perioda							
Ukaz	1	2	3	4	5	6	7	8	9
LW R3,56(R4)	IF	ID	EX	MEM	WB				
SUB R1,R3,R6		IF	0	ID	EX	MEM	WB		
ADD R2,R3,R7				IF	ID	EX	MEM	WB	
XOR R8,R3,R9					IF	ID	EX	MEM	WB

PARALELIZEM NA NIVOJU UKAZOV

3

# Rešitev 3: Cevovodno razvrščanje (pipeline scheduling)

- Prevajalnik lahko s spreminjanjem vrstnega reda ukazov pogosto odpravi nevarnost
- Npr.:

	a = b + c $d = e - f$	(naslovi naj bodo v registrih Ra,, Rf)
LW	R2,0(Rb)	$R2 \leftarrow b$
LW	R3,0(Rc)	$R3 \leftarrow c$
LW	R4,0(Re)	R4 ← e ukaz prestavljen naprej
ADD	R5,R2,R3	$R5 \leftarrow b + c$
LW	R6,0(Rf)	R6 ← f ukaz prestavljen naprej
SW	0(Ra),R5	$a \leftarrow b + c$
SUB	R7,R4,R6	R7 ← e − f
SW	0(Rd),R7	$d \leftarrow e - f$

PARALELIZEM NA NIVOJU UKAZOV

## Večina prevajalnikov danes uporablja cev. razvrščanje

- · čakanja pa se vedno ne da odpraviti
- delež ukazov load, kjer se kljub temu pojavi PN:
  - 4 40% (odvisno od programa), povprečno pa 19%
  - ukazov load je v povp. 24%
  - 0,19\*0,24=0,0456
  - $\circ$  CPI = (1 0.0456)\*1 + 0.0456\*2 = 1.0456
  - zaradi PN pri load je cevovod za 4,6% počasnejši

PARALELIZEM NA NIVOJU UKAZOV

35

## Kontrolne nevarnosti

## KN: pri ukazih, ki spremenijo PC drugače kot PC $\leftarrow$ PC + 4

- to so kontrolni ukazi oz. skoki:
  - o brezpogojni skoki, pogojni skoki, klici (procedur), vrnitve
  - J, BEQ, BNE, CALL, TRAP, RFE
- skočni naslov se prenese v PC (v stopnji EX, razen pri TRAP (WB))
- KN: Kadar se v stopnji EX spremeni PC, je vsebina stopenj IF in ID neveljavna!
  - v njiju sta ukaza, ki sledita skočnemu ukazu
  - ne smeta se izvršiti
  - najenostavnejša rešitev je vstavljanje mehurčka v IF in ID

PARALELIZEM NA NIVOJU UKAZO

# Odpravljanje kontrolnih nevarnosti

#### Prvi korak je zmanjšanje skočne zakasnitve:

- Preverjanje pogoja za skok naj se izvaja čim bližje prvi stopnji cevovoda
- Izračun skočnega naslova naj se izvaja čim bližje prvi stopnji cevovoda
- HIP: preverjanje skočnega pogoja je v BEQ in BNE
  - računanje skočnega naslova je možno v že stopnji ID
    - BEQ in BNE uporabljata PC-relativno naslavljanje, vrednost PC pa je že v reg.
       PC1
  - preverjanje pogoja šele v stopnji EX (komparator za B=0)

PARALELIZEM NA NIVOJU UKAZOV

37

## Vstavljanje mehurčkov

- Najenostavnejša (a bolj slaba) rešitev je vstavljanje mehurčka v IF
- V tem primeru se v primeru skoka razveljavi ukaza v IF in ID (z mehurčki), če pa se skok ne izvede, pa deluje normalno naprej brez ustavljanja
  - $^{\circ}\,$  skočna zakasnitev (branch delay), čakanje 2 periodi (pri TRAP izjemoma 5 period)
- · Vsak skočni ukaz (z izjemo TRAP) povzroči 2 čakalni periodi

					Urina	period	a			
Št. ukaza	1	2	3	4	5	6	7	8	9	10
Skočni ukaz	IF	ID	EX	MEM	WB					
Skočni ukaz + 1		IF	0	IF	ID	EX	MEM	WB		
Skočni ukaz + 2					IF	ID	EX	MEM	WB	
Skočni ukaz + 3						IF	ID	EX	MEM	WB
Skočni ukaz + 4							IF	ID	EX	MEM

PARALELIZEM NA NIVOJU UKAZOV

- če pogoj za skok ni izpolnjen, ni čakanja
- o cevovod predpostavi, da skoka ne bo

#### · V povprečju:

- pogojnih skokov 12,5%
  - ∘ pogoj izpolnjen pri ~ 2/3 primerov
- brezpogojnih skokov 2,5%

#### • Sprememba PC v stopnji EX:

- · 0,125\*2/3 + 0,025 = 0,109
- pri 10,9% ukazov je CPI = 3, sicer 1
- CPI = 3\*(0,109) + 1\*(1 0,109) = 1,218
  - tj. več kot 20% izguba (daljši čas računanja)
- Pri rač. z dolgimi cevovodi in pri CISC so izgube še večje
- KN so najhujše od 3 vrst nevarnosti

ARALELIZEM NA NIVOJU UKAZOV

39

## Drug način je <u>predikcija izpolnitve skočnega pogoja in</u> <u>napoved skočnega naslova</u> (če se skok izvede)

- branch predictor je vezje, ki napoveduje (ne)izpolnjenost pogoja
- 2 skupini:
- s statično predikcijo
- · z dinamično predikcijo

PARALELIZEM NA NIVOJU UKAZOV

### Statična predikcija z zakasnjenimi skoki

## Prevajalnik skuša napovedati bolj verjeten rezultat preverjanja skočnega pogoja

- med izvrševanjem programa se zato ne spreminja → statična predikcija
- tudi že omenjeni primer (ki predpostavi neizpolnjenost pogoja) je preprost primer statične predikcije
- skočne reže (branch slots)
  - v njih so ukazi, ki so v programu za skokom
  - enako številu stopenj cevovoda, ki so pred stopnjo, v kateri se v PC zapiše skočni naslov
    - pri HIP je to EX, pred njo sta 2 stopnji (zato 2 skočni reži)

PARALELIZEM NA NIVOJU UKAZOV

4

## Pri uporabi zakasnjenih skokov se (ne glede na izpolnjenost pogoja) izvršijo vsi prevzeti ukazi

- ukaza (oz. ukazi) v skočnih režah se ne nadomestita z mehurčki
- ker se vedno izvršita (izvršijo), izgleda kakor da se skok izvede kasneje

#### Primer:

Prvotno ukazov	zaporedje	•	njeno zaporedje pri zakasnjenih skokil	n
XOR	R1,R2,R3	XOR	R1,R2,R3	
ADD	R4,R6,R7	JMP	88(R20)	
SUB	R8,R5,R10	ADD	R4,R6,R7	skočna reža 1
JMP	88(R20)	SUB	R8,R5,R10	skočna reža 2
AND	R2,R2,R3	AND	R2,R2,R3	
OR	R7,R4,R9	OR	R7,R4,R9	

- Ukaza ADD in SUB se prestavita v skočni reži
- Pri desnem zaporedju ni čakalnih period

PARALELIZEM NA NIVOJU UKAZOV

#### Pri pogojnih skokih je težje:

- ukaza, ki vpliva na pogoj, ne smemo dati v režo!
- namesto njega damo ukaz NOP (to dela prevajalnik)
  - o prebere se iz ukaznega PP
  - o možno je tudi, da bi bila oba ukaza NOP (lahko pa tudi nobeden)

Prvotno zaporedje ukazov	Spremenjeno zaporedje ukazov pri zakasnjenih skokih	
L1: XOR R1,R2,R3	L1: XOR R1,R2,R3	
ADD R4,R6,R7	SUB R8,R5,R10	
SUB R8,R5,R10	BEQ R8,L1	
BEQ R8,L1	ADD R4,R6,R7	skočna reža 1
AND R2,R2,R3	NOP	skočna reža 2
OR R7,R4,R9	AND R2,R2,R3	
	OR R7,R4,R9	

PARALELIZEM NA NIVOJU UKAZOV

43

#### Meritve (na cevovodih z eno skočno režo):

- pri pogojnih skokih se koristno zapolni ~ 70% rež
- če upoštevamo še brezpogojne skoke (kjer so reže vedno koristno zasedene), se št. čakalnih urinih period zmanjša na 25%

## Ugotovljeno je bilo, da se druga reža koristno zapolni 2x redkeje kot prva

- pri HIP bi pričakovali zmanjšanje čakalnih period na ~ 40%
- o pri skokih se namesto 2 izgubi 0,8 periode

PARALELIZEM NA NIVOJU UKAZOV

#### CPI:

 $CPI_{idealni} = (1 - 0.109)*1 + 0.109*1.8 = 1.087$ 

- dosti bolje od 1,218
- če bi uporabili še razvelj. skoke, bi bilo še bolje
- pri dolgih cevovodih pa je koristno zapolniti reže težko

#### Statična predikcija

- prednost: večino dela opravi prevajalnik
- hiba: večino dela opravi prevajalnik
  - ∘ zahteva drugačno programiranje → problemi s kompatibilnostjo za nazaj

Danes se bolj uporabljajo strojni načini za dinamično predikcijo skokov

PARALELIZEM NA NIVOJU UKAZOV

4

## Dinamična predikcija skokov

#### Prilagaja se dogajanju v programu

#### Več vrst dinamične predikcije:

- 1. 1-bitna prediktorska tabela
  - prediktorska tabela (branch prediction table, branch history
  - to je majhen pomnilnik, iz katerega se v stopnji IF bere vrednost (1 bit pri 1-bitni tabeli)
  - naslov določajo spodnji biti naslova ukaza
  - če je pogoj izpolnjen, se vpiše 1, sicer 0
    - v stopnji EX, ko je to znano

PARALELIZEM NA NIVOJU UKAZO

- služi kot napoved izpolnjenosti pogoja
- če je napovedan izpolnjen pogoj, potrebujemo še skočni naslov
  - ta je dostopen šele v stopnji ID
  - zato privarčujemo le en urino periodo (pri HIPu)
  - če je bila napoved napačna (izvemo v EX), je treba v IF in ID vstaviti mehurčke
- metoda ni posebno zanesljiva
  - npr. pri vgnezdenih zankah bo napoved tipično napačna dvakrat

PARALELIZEM NA NIVOJU UKAZOV

4

#### 2. 2-bitna prediktorska tabela

- 4 vrednosti (0..3)
- Povečanje ali zmanjšanje za 1
- 0 in 1: neizpolnjen pogoj, 2 in 3: izpolnjen
- Pri vgnezdenih zankah le 1 napačna napoved

#### Možna tudi n-bitna prediktorska tabela, n > 2

- Vendar ni dosti boljša kot 2-bitna
- Tabele so velikosti največ 4096 (12 bitov naslova)

PARALELIZEM NA NIVOJU UKAZO\

#### 3. Korelacijski prediktor

Correlating branch prediction table

Primer:

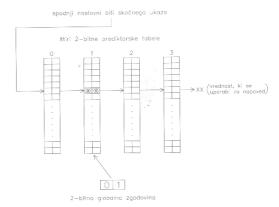
```
SUBI
                     R3,R1,#2
          BNE
                     R3,L1
                                           ; skok s1
          ADD
                     R1,R0,R0 ; a \leftarrow 0
L1:
          SUBI
                     R3,R2,#2
          BNE
                     R3,L2
                                           ; skok s2
          ADD
                     R2,R0,R0; b \leftarrow 0
L2:
          SUBI
                     R3,R1,R2; R3 \leftarrow a - b
           BEQ
                     R3,L3
                                           ; skok s3
```

- Skok s3 odvisen od s1 in s2
- Običajna prediktorska tabela tega ne more zajeti

PARALELIZEM NA NIVOJU UKAZOV

4

- Korelacijski prediktor (m,n) uporablja obnašanje prejšnjih m skokov (t.i. globalna zgodovina), da izbere eno od 2<sup>m</sup> n-bitnih predliktorskih tabel
  - Navadna 2-bitna tabela bi bila k.p. (0,2)
    - Imenuje se tudi lokalni prediktor
- Primer: korelacijski prediktor (2,2)
  - Za globalno zgodovino lahko uporablja 2-bitni pomikalni register (pomika v levo)



PARALELIZEM NA NIVOJU UKAZOV

#### 4. Turnirski prediktor

- tournament branch predictor
- Upošteva dejstvo, da globalni prediktor ni vedno boljši od lokalnega
- Paralelno delojoča lokalni in globalni prediktor tekmujeta
- Selektor določa, kateri bo uporabljen (glede na prejšnji uspeh)

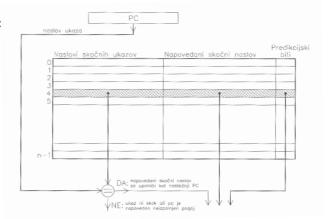
#### 5. Skočni predpomnilnik

- branch target buffer
- Tudi pri pravilni napovedi pogoja se vedno izgubi ena perioda
  - V stopnji IF ne poznamo skočnega naslova (ne poznamo niti ukaza, ker še ni dekodiran)
- Skočni PP vsebuje skočne naslove zadnjih skokov, pri katerih je bil pogoj izpolnjen
  - Naslovi se vanj shranijo v stopnji EX
- V IF se poleg ukaza bere tudi skočni PP
  - V primeru zadetka (in potencialnih prediktorskih bitov) se skočni naslov takoj vpiše v PC
  - Pri pravilni napovedi ni treba čakati 1 periodo
  - Pri napačni napovedi (ali skočnem naslovu) je treba vstavljati mehurčke

PARALELIZEM NA NIVOJU UKAZOV

51

Skočni predpomnilnik:



Skočni PP je bolj zapleten od prediktorjev na osnovi tabel

• Npr. PP 1024x32 potrebuje 1024 32-bitnih komparatorjev (primerjalnikov)

V skočni PP se shrani skočni naslov le, kadar je pogoj izpolnjen

• Sicer je naslov poznan (naslednji po vrsti)

PARALELIZEM NA NIVOJU UKAZO

#### 6. Vrnitveni prediktor

- return address predictor
- Težavna vrsta posrednih skokov
- Ista procedura se lahko kliče z zelo različnih mest v programu (npr. funkcija printf v C-ju)
  - Težko napovedati
- · Običajno majhen sklad (npr. 16 naslovov)

#### 7. Enota za prevzem ukazov

- integrated instruction fetch unit
- Današnji računalniki lahko istočasno prevzemajo in izvršujejo več ukazov (superskalarnost)
  - Prevzem ukazov bolj zapleten
- Enota deluje samostojno in dostavlja ukaze ostalim stopnjam
  - Dela tudi predikcijo, dostopa do PP, pri zgrešitvah menjava bloke v PP, ...

PARALELIZEM NA NIVOJI I I KAZOV

53

#### Vključitev dinamične predikcije v HIP

HIP ima skočno zakasnitev 2 urini periodi

Odločimo se npr. za skočni predpomnilnik (SPP) z enim prediktorskim bitom

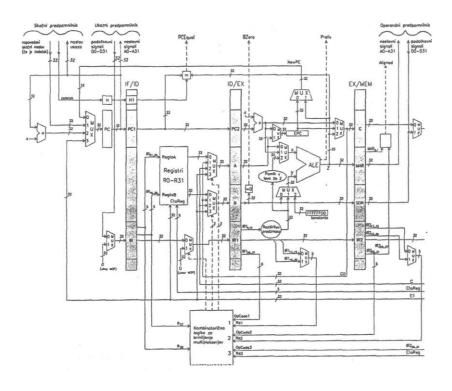
 ta bit prepreči, da bi se informacija o skoku izbrisala iz PP že ob prvi napačni napovedi

V stopnji IF gre vsebina PC v ukazni in v SPP

Če je v SPP zadetek, se napovedani naslov iz njega prenese v PC

- $^{\circ}\,$ s tega naslova naj bi stopnja IF prevzela naslednji ukaz
- skočni ukaz pa se izvršuje naprej (v ID in EX), ker napoved morda ni pravilna

PARALELIZEM NA NIVOJU UKAZO



#### Modifikacije podatkovne enote:

- mux 4/1 (namesto 3/1) zaradi SPP
- 1-bitni register H
  - ob zadetku se vanj vpiše 1, ob zgrešitvi 0
  - H je potreben zato, ker se mora v EX preveriti pravilnost skočnega naslova (ob zadetku se je vpisal v PC)
- komparator v ID
  - primerja napovedani (v PC1, stopnja ID) in izračunani (na izhodu ALE, stopnja EX) skočni naslov
  - njegov izhod je PCEqual
    - 0 pri neenakosti, če je hkrati H1=1
    - 1 sicer
  - kadar je PCEqual=1, je bila napoved naslova pravilna
  - skočnemu ukazu v EX se ne dovoli pisanje v PC
  - sicer je bila napačna
    - tedaj sta napačna tudi ukaza v IF in ID
    - v IF in ID se vstavita mehurčka
  - v PC se prenese NewPC = PC2 + 4 + razIR1<sub>0..15</sub>
  - v stopnji EX se mora osvežiti informacija v skočnem PP (v primeru skoka)
    - način odvisen od
      - izpolnitve pogoja
      - zadetka v skočnem PP (H1)
      - prediktorskega bita

PARALELIZEM NA NIVOJU UKAZO

- 1. Skočni pogoj je izpolnjen
  - v primeru zadetka v SPP se prediktorski bit postavi na 1
  - sicer se naslov skočnega ukaza in izračunani skočni naslov shranita v SPP (predikt. bit 1)
- 2. Skočni pogoj ni izpolnjen
  - v primeru zadetka v SPP
    - o in predikt. bita 0, se info. o tem skočnem ukazu izbriše iz SPP
    - o in predikt. bita 1, gre le-ta v 0, info. pa ostane v SPP
  - sicer nič
- stanje predikt. bita se torej uporablja le pri odločitvi o brisanju info. iz SPP
- zadetek v SPP pri HIPu pomeni, da je napovedan izpolnjen pogoj
  - ne glede na stanje predikt. bita

PARALELIZEM NA NIVOJU UKAZOV

57

#### Uspešnost dinamične predikcije pri HIP

- verjetnost zadetka v SPP H<sub>c</sub> naj bo 90%
  - za to zadošča že majhen SPP, velikosti 64
- verjetnost, da zadetek v SPP pomeni pravilno napoved, H<sub>n</sub> naj bo 92%
- pogoj za skok naj bo izpolnjen z verjetnostjo 67,3%

Zadetek v SPP	Napoved izpolnjenosti pogoja	Dejanska izpolnjenost pogoja	Število čakalnih period		
da	izpolnjen	izpolnjen	0		
da	izpolnjen	neizpolnjen	2		
ne	neizpolnjen	izpolnjen	2		
ne	neizpolnjen	neizpolnjen	0		

PARALELIZEM NA NIVOJU UKAZOV

Čakalne periode pogojni skok

= 
$$H_c$$
 \*  $(1-H_p)$  \* 2 +  $(1-H_c)$  \* verj. za izpolnjen skočni pogoj \* 2  
=  $0.9*0.08*2 + (1-0.9)*0.673*2$ 

$$= 0,279$$

Čakalne periode  $_{\text{brezpogojni skok}} = (1-H_c)^2 = (1-0.9)^2 = 0.2$ 

$$\text{\"{Cakalne periode}}_{\text{skok}} \ = \frac{0,125 \times 0,279 + 0,025 \times 0,2}{0,125 + 0,025} = 0,266$$

$$CPI_{idealni} = (1 - 0.15)*1 + 0.15*1.266 = 1.04$$

4% je približno 2x manj kot pri statični predikciji

Škoda zaradi zgrešitev v PP je znatno večja (v gornjih enačbah ni upoštevana)

PARALELIZEM NA NIVOJU UKAZOV

59

## Prekinitve in pasti pri cevovodu

#### Kdaj skočiti na servisni program?

- istočasno se izvaja več ukazov
- o delno izvršeni ukazi lahko povzročijo napake

#### 3 primeri

#### 1. Vhodno/izhodne prekinitve

- običajno je, da cevovod izvrši ukaze (ki so že v njem) do konca
  - V/I prekinitve so razmeroma redki dogodki, zato izguba ni velika
- pri HIP je prekinitveno-prevzemni cikel treba izvesti izven cevovoda (sicer bi rabili 6 stopenj v cevovodu)

PARALELIZEM NA NIVOJU UKAZO

#### 2. Programske pasti

- TRAP je v bistvu kot klic procedure
  - poseben brezpogojni skok

#### 3. Pasti, do katerih pride med izvrševanjem ukaza

- najtežje
- zgodijo se na sredi ukaza
  - ukaz se ne more dokončati
  - potrebno ga je ustaviti, izvršiti servisni program in ga ponovno začeti
    - treba je tudi paziti, da del ukaza, ki se je (bil) že izvršil, ne povzroči napake

PARALELIZEM NA NIVOJU UKAZO\

61

Stopnja cevovoda	Problematične pasti pri HIP
IF	napaka strani (pri branju ukaza), zaščita pomnilnika
ID	nedefiniran ukaz
EX	preliv
MEM	napaka strani (pri dostopu do operanda), zaščita pomnilnika neporavnan operand,
WB	nobena

- napaka strani: pri navideznem (virtualnem) pomnilniku, kadar stran ni (fizično) v GP (ne gre za resnično napako)
- zaščita pomnilnika: dostop do naslova, ki ne pripada programu
- pri napaki strani se po servisiranju program nadaljuje na prekinjenem mestu
- pri ostalih pasteh se običajno zaključi z diagnostičnim sporočilom

PARALELIZEM NA NIVOJU UKAZO

## Operacije, ki trajajo več urinih period

Ko ukaz s tako operacijo pride v stopnjo EX, se cevovod ustavi in čaka, da se operacija izvrši

o cevovod bi pri mnogih programih postal prepočasen

#### Zato so uvedli funkcijske enote:

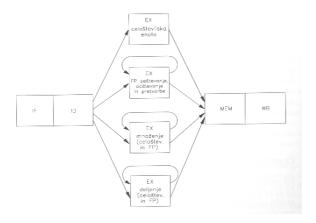
- · Celoštevilska enota (integer unit)
  - o celošt. ALE ukazi, skoki, load, store
  - o pri HIP je le ta
- Enota za operacije v plavajoči vejici (floating-point unit)
  - seštevanje, odštevanje, pretvorbe
- Enota za množenje
  - · celoštevilsko in v FP
- Enota za deljenje
  - · celoštevilsko in v FP

PARALELIZEM NA NIVOJI I I KAZOV

63

#### Predpostavimo, da FE niso cevovodne

- naslednji ukaz lahko uporabi neko enoto šele, ko jo prejšnji zapusti (strukturne nevarnosti)
- o samo celošt. enota rabi 1 periodo, ostale več



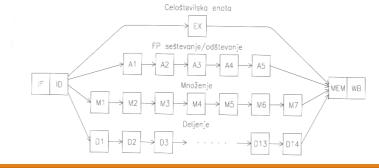
PARALELIZEM NA NIVOJU UKAZOV

## Če so FE cevovodne (danes običajno), lahko odpravimo strukturne nevarnosti v ID in EX

• lahko pa se SN pojavijo v MEM in WB

#### Dodatni problemi:

- V MEM in WB pride hkrati lahko več rezultatov
  - reg. blok mora omogočati več pisanj vanj hkrati
- o poveča se tudi verjetnost podatkovnih nevarnosti
  - v MEM in WB prihajajo ukazi v spremenjenem vrstnem redu
  - o pojavijo se PN tipov WAW in WAR



PARALELIZEM NA NIVOJU UKAZOV

65

#### 3 vrste PN:

- RAW (read after write): ukaz j bere operand, preden ga ukaz i shrani
- WAR (write after read): ukaz j piše v reg., še preden ga i prebere
- $\circ$  WAW (write after write): ukaz j piše v reg., preden vanj piše i
- RAR ne more povzročiti PN

#### Pri HIP je edina možnost RAW

• s premoščanjem jo običajno odpravimo (razen pri load)

PARALELIZEM NA NIVOJU UKAZO

#### Primer: zaporedje ukazov v plavajoči vejici

- enota (FPU) ima kar svojo množico registrov
  - o poenostavi ugotavljanje nevarnosti
  - to rešitev uporablja večina CPE

								Uri	ina p	erio	oda							
Ukaz	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
FLD F4,0(R2)	IF	ID	EX	ME M	WB													
FMUL F0,F4,F6		IF	ID	0	M1	M2	М3	M4	M5	M6	M7	ME M	WB					
FADD F2,F0,F8			IF	0	ID	0	0	0	0	0	0	A1	A2	А3	A4	A5	ME M	WB
FST 0(R2),F2					IF	0	0	0	0	0	0	ID	EX	0	0	0	0	ME M

PARALELIZEM NA NIVOJU UKAZOV

67

# Odpravljanje podatkovnih nevarnosti z dinamičnim razvrščanjem

#### Dinamično razvrščanje:

 strojna sprememba vrstnega reda izvrševanja ukazov (da se zmanjša št. čakalnih period)

#### Primer PN:

- čakanje na "počasen" ukaz, ki se izvršuje v neki FE
- o npr.:

```
FDIV F0,F5,F6 ; F0 \leftarrow F5/F6

FADD F4,F0,F2 ; F4 \leftarrow F0 + F2

FSUB F8,F2,F1 ; F8 \leftarrow F2 - F1
```

- ukaz FSUB mora čakati (cevovod se ustavi zaradi odvisnosti med FDIV in FADD)
- ker pa je FSUB neodvisen od prejšnjih ukazov, ga lahko pomaknemo gor (da se izogne čakanju)

PARALELIZEM NA NIVOJU UKAZO

#### ID moramo razdeliti na 2 stopnji:

- Izstavljanje (issue)
  - dekodiranje
  - ugotavljanje SN
    - pri SN izvrševanje ukaza ni možno (ne glede na PN)

#### 2. Branje operandov

- ugotavljanje PN
  - v primeru nevarnosti se čaka
  - v tej stopnji lahko pride do spremembe vrstnega reda ukazov

#### Spremenjen vrstni red izvrševanja lahko pripelje do PN tipa WAR in WAW

Tomasulov algoritem (1967)

#### Podatkovne odvisnosti lahko delimo na

- prave podatkovne odvisnosti
  - ukaz potrebuje kot vhodni operand rezultat enega od prejšnjih ukazov
- imenske odvisnosti

PARALELIZEM NA NIVOJU UKAZOV

6

```
FDIV F0,F5,F6 ; F0 \leftarrow F5/F6

FADD F4,F0,F2 ; F4 \leftarrow F0+F2

FST 0(R1),F4 ; M[R1] \leftarrow F4

FSUB F2,F3,F7 ; F2 \leftarrow F3-F7

FMUL F4,F3,F2 ; F4 \leftarrow F3*F2
```

- imenske odvisnosti
  - med FADD in FSUB zaradi R2
    - nevarnost WAR (antiodvisnost)
  - med FADD in FMUL zaradi F4
    - nevarnost WAW (izhodna odvisnost)
- prave podatkovne odvisnosti
  - med FDIV in FADD
  - med FADD in FST
  - med FSUB in FMUL

PARALELIZEM NA NIVOJU UKAZO

Imenske odvisnosti lahko vedno odpravimo s preimenovanjem registrov (če imamo na voljo dodatne registre)

FDIV	F0,F5,F6	F0 ← F5/F6
FADD	<b>FT2</b> ,F0,F2	<b>FT2</b> ← F0+F2
FST	0(R1), <b>FT2</b>	$M[R1] \leftarrow FT2$
FSUB	<b>FT1</b> ,F3,F7	<b>FT1</b> ← F3-F7
FMUL	F4,F3, <b>FT1</b>	F4 ← F3* <b>FT1</b>

Tomasulov algoritem pa odpravi nevarnosti, ki izvirajo iz imenskih odvisnosti (WAR in WAW), brez preimenovanja registrov

PARALELIZEM NA NIVOJU UKAZOV

71

## Špekulativno izvajanje ukazov

Pri dinamičnem razvrščanju ukazov se problemi zaradi KN zelo povečajo

- ker se v vsaki periodi izvršuje več ukazov, je v primeru napačne predikcije težko ugotoviti, kateri se morajo razveljaviti
- cevovod se mora ustavljati

Špekulativno izvajanje ukazov (speculative execution)

- predpostavi se, da je napoved skokov z dinamično predikcijo pravilna
- potreben pa je mehanizem, ki v primeru napačne napovedi odstrani vse, kar so naredili napačno napovedani ukazi
  - izvršitev ukaza ne sme vplivati na registre, dokler ni potrjena pravilnost napovedi skoka
  - preureditveni izravnalnik (reorder buffer, ROB)
    - začasno hrani rezultate ukazov

PARALELIZEM NA NIVOJU UKAZO

Preureditveni izravnalnik je realiziran kot FIFO vrsta v obliki krožnega bufferja

• ukazi so v njem v pravilnem vrstnem redu

#### Vsako polje v njem ima 4 parametre:

- 1. vrsta ukaza
  - skoki, store ali registrski ukazi
- ponor
  - register ali pomnilniška beseda
- 3. vrednost
  - rezultat ukaza, ki naj se shrani
- 4. veljavnost
  - 1, če je v parametru vrednost že rezultat ukaza
  - 0, če se na rezultat ukaza še čaka

Velikost preureditvenega izravnalnika se imenuje *ukazno okno* (instruction window)

- o določa, koliko ukazov se lahko izvede špekulativno
- če je velika, se porabi več energije za izbris vsega izračunanega

PARALELIZEM NA NIVOJI I I KAZOV

73

## Večizstavitveni procesorji

#### Približevanje CPI vrednosti 1

- o dinamična predikcija skokov
- dinamično razvrščanje
- špekulativno izvrševanje ukazov

#### **CPI < 1**

- v vsaki urini periodi se mora prevzeti in izstaviti več kot 1 ukaz
- običajno se uporablja IPC = 1 / CPI
- večizstavitveni procesorji (multiple issue processors)

PARALELIZEM NA NIVOJU UKAZOV

#### Vidiki prevzema in izstavljanja ukazov

#### Prevzem ukazov

- izstavitev n ukazov zahteva, da je ukazni PP sposoben dostavljati n ukazov v periodi
- treba je povečati širino dostopa do čakalne vrste in zmogljivost pomnilnika

#### Izstavljanje ukazov

- če je med (n) ukazi skok z napovedanim skočnim pogojem, se preostali ukazi ne izstavijo
  - prevzem ukazov v naslednji periodi pa se začne z napovedanega skočnega naslova
- potrebno je tudi preveriti medsebojne odvisnosti med operandi
  - pri n ukazih s 3 reg. operandi je potrebnih n(n-1) primerjav (2(n-1) + 2(n-2) ...)

Strojno ugotavljanje podatkovnih odvisnosti je zahtevno za realizacijo, zato sta se pojavili 2 rešitvi:

- 1. Superskalarnost
- 2. VLIW

PARALELIZEM NA NIVOJU UKAZO

7.

## Superskalarni procesorji

Dinamično določanje, kateri ukazi se v dani periodi ure izstavijo

 če se jih lahko izstavi največ n, je to n-kratni superskalarni procesor (n-way superscalar processor)

n(n-1) primerjav je težko izvesti v eni periodi

 pri superskalarnih procesorjih se primerjave razdeli med več stopenj cevovoda

Ukazi se sicer izvajajo špekulativno

- le da jih je več hkrati
- Št. FE običajno > n, da se zmanjšajo SN

Potrebujejo pa večjo zmogljivost:

- prenosnih poti,
- o preureditvenega izravnalnika,
- dostopa do registrov

PARALELIZEM NA NIVOJU UKAZO

#### Najbolj zapleteni del superskalarnega procesorja je ROB

## Zato procesorji po letu 2000 uporabljajo **eksplicitno preimenovanje registrov**

- preureditveni izravnalnik je preprostejši
  - skrbi le za vrstni red ukazov, ne pa tudi za operande iz registrov
- procesor ima še dodatne registre
  - razširjena množica registrov (lahko tudi nekaj sto)
  - o preimenovalna tabela določa, kateri so v neki periodi programsko dostopni
- korak izstavljanja je drugačen:
  - Iz čakalne vrste se vzame n ukazov
  - o Izhodni register vsakega ukaza se preimenuje v enega od prostih registrov
    - S tem se odpravijo nevarnosti WAW in WAR, ki izvirajo iz imenskih odvisnosti
  - Preveri se medsebojna odvisnost operandov (kot že prej opisano)
    - Po potrebi se popravijo številke vhodnih registrov
  - Ukazi se prenesejo v ROB
    - Globina se določi na osnovi števila registrov
  - Ukazi se prenesejo v FE

DADALELIZERANIA NUMOULUKAZON

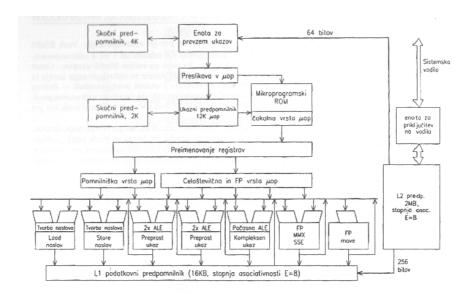
77

#### Primer superskalarnega procesorja: Pentium 4

- mikroarhitektura NetBurst
- 7 FE:
  - load
  - store
  - preproste celoštevilske operacije (x2)
  - zahtevne celoštevilske operacije
  - FP operacije
  - o prenosi FP operandov iz/v pomnilnik

PARALELIZEM NA NIVOJU UKAZOV

#### Pentium 4



## Procesorji VLIW

## Procesorji VLIW (very long instruction word) imajo dolge ukaze

- · Vsebujejo več običajnih ukazov, ki se lahko izvršujejo paralelno
  - Npr. da vsak zaposli eno FE
- Tipičen ukaz:
  - 3 celošt. ukazi
  - 2 FP ukaza
  - · 2 pomnilniška dostopa
  - 1 skok
- · CPE ne ugotavlja odvisnosti in nevarnosti
  - To je delo prevejalnika
  - Če ne uspe najti dovolj neodvisnih ukazov za vse enote, se nekaterim FE da ukaz NOP

PARALELIZEM NA NIVOJU UKAZO

#### Potencialne prednosti VLIW:

- Prevajalnik vidi celoten program
  - · Zato lahko odkrije več paralelnosti kot logika v procesorju, ki vidi le ukazno okno
  - Odkrivanje paralelnosti se izvede samo enkrat
- · Procesor je lahko preprostejši
  - Ne rabi logike za odkrivanje paralelnosti
  - · Zato je frekvenca ure lahko višja

#### Digitalno procesiranje signalov

· Veliko paralelnosti

#### EPIC (explicitly parallel instruction computing)

- Intel 1997
- predikatni ukazi
- Itanium 1 (2000), 2 (2002)

PARALELIZEM NA NIVOJU UKAZOV

8

# Omejitve paralelizma na nivoju ukazov

#### Količina paralelnosti v programih je omejena

• S povečevanjem količine logike lahko pridobimo le do neke meje

Koliko paralelnosti na nivoju ukazov je v nekem programu?

- · zamislimo si idealni superskalarni procesor
- lastnosti:
  - 1. ni strukturnih nevarnosti
    - neomejeno število registrov za preimenovanje
    - neomejeno število FE, vse izvršijo operacijo v 1 periodi
    - torej se v 1 periodi lahko izstavi in izvrši neomejeno število ukazov
  - ni kontrolnih nevarnosti
    - popolno napovedovanje skokov (vsi napovedani 100%)
    - neomejeno ukazno okno
    - do izbrisa zaradi napačne špekulacije nikoli ne pride

PARALELIZEM NA NIVOJU UKAZO

- 3. naslovi vseh pomnilniških operandov znani vnaprej
  - ukazi load se lahko prestavijo pred store (če ne gre za isti naslov)
- 4. predpomnilniki nimajo zgrešitev
  - vsi pomnilniški dostopi trajajo 1 periodo
- ostanejo le prave podatkovne nevarnosti
- izvajamo različne programe in merimo dosegljivi IPC
  - na 6 programih iz SPEC92
    - IPC od 18 do 150
    - povprečni IPC okrog 80
  - z upoštevanjem bolj realnih lastnosti dosegljivi IPC pade na okrog 5
  - realni IPC pa je manjši

PARALELIZEM NA NIVOJU UKAZOV

8

## Paralelizem na nivoju niti

Paralelizem na višjem nivoju, ki ga na nivoju ukazov ni mogoče izkoristiti

- izvrševanje se razdeli v več neodvisnih poti (niti)
  - thread-level parallelism
- Pri večnitnosti (multithreading) si niti delijo FE enega procesorja
- vsaka nit ima svoje stanje
  - ločeno in neodvisno od drugih niti
  - nit ima svojo kopijo registrov, svoj PC, svoje tabele strani in nekatere programsko nevidne registre
- o niti pa si delijo GP in PP
- o nit vidi procesor, kakor da je namenjen le njej sami
  - en fizični procesor je videti kot več logičnih procesorjev
- problem: niti je treba definirati (paralelno programiranje)
  - eksplicitni paralelizem
  - obstoječe programe je (bi bilo) potrebno predelati!

PARALELIZEM NA NIVOJU UKAZO

#### Več oblik večnitnosti:

- Časovna večnitnost (temporal multithreading)
  - preklapljanje, niti se izmenjujejo
  - a. Drobno-zrnata večnitnost
    - preklop med nitmi vsako urino periodo
    - treba je shraniti celotno stanje cevovoda
    - če bi posamezna nit morala čakati, se jo v tem ciklu izpusti (da se ne izgublja časa)
    - hiba je upočasnitev posameznih niti
  - b. Grobo-zrnata večnitnost
    - preklop samo, kadar pride pri niti do daljšega čakanja
    - ni treba shraniti stanja cevovoda (čakamo, da se izprazni)

#### 2. Istočasna večnitnost (simultaneous multithreading, SMT)

- pri večizstavitvenih procesorjih
  - Intel Pentium 4: Hyper-threading (običajno 2 niti)
- o ni potrebno veliko sprememb
- prednost: ni medsebojnih odvisnosti
- hiba: v določenih primerih se zmogljivost tudi poslabša
  - programerji morajo preverjati, ali se pri neki aplikaciji SMT obnese, ali ne

PARALELIZEM NA NIVOJU UKAZOV

85

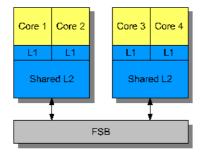
## Večjedrni procesorji (multicore)

- več CPE (jeder) na istem čipu
- pogosto imajo CPE svoje PP L1, L2 in višje pa si delijo
  - zato CPE niso čisto neodvisne
  - jedra so običajno tudi večnitna (pogosto dvonitna)
- množična proizvodnja večjedrnih procesorjev
  - predvsem v interesu proizvajalcev
    - ceneje kot vlagati v razvoj novih rešitev
  - uporabniki redko lahko uporabijo veliko število jeder
  - Npr., procesor z IPC = 4 bi bil verjetno bolj koristen kot 8jedrni
  - "uporabniki se bodo pač morali naučiti pisanja večnitnih programov" ?!

PARALELIZEM NA NIVOJU UKAZO

#### Primer:

• Intel Core 2 Quad



PARALELIZEM NA NIVOJU UKAZOV