

Teorija
Informacij
in sistemov,
predavanje
2

ULotric

2.
Kodiranje

2.1
Lastnosti
kodov

2.2
Kraftova
neenakost

2.3
Shannonov
prvi teorem

3. Stiskanje

3.1
Shannonov
kod

3.2 Fanojev
kod

Teorija Informacij in sistemov, predavanje 2

Uroš Lotrič

Univerza v Ljubljani,
Fakulteta za računalništvo in informatiko

- ▶ Vzemimo, da vsako sporočilo ustreza enemu dogodku.
- ▶ Sporočila so lahko: znaki abecede, številke 0-9, 0 in 1, ...
- ▶ **Kod** sestavljajo **kodne zamenjave**, ki so sestavljene iz znakov **kodne abecede**. Število znakov v kodni abecedi označujemo z r .
- ▶ Kodno abecedo največkrat predstavljata znaka 0 in 1, lahko je tudi večja.
- ▶ **Kod** je dodelitev kodnih zamenjav znakom osnovne abecede
- ▶ Primer: A - 0, B - 01, C - 010
- ▶ Mnogi kodi so zelo splošno uporabljani:
 - ▶ Morsejeva koda {., -, presledek}, SOS = ...- - -...
 - ▶ koda ASCII: A - 1000001, B - 1000010

- ▶ Pomembna lastnost koda je dolžina kodnih zamenjav
- ▶ Kratke kodne zamenjave so bolj zaželenene
 - ▶ Morse: E = ., A = .-, Y = - . . -
- ▶ Če so $\{p_1, \dots, p_n\}$ verjetnosti znakov $\{s_1, \dots, s_n\}$ osnovnega sporočila in $\{l_1, \dots, l_n\}$ dolžine prirejenih kodnih zamenjav je povprečna dolžina kodne zamenjave $= L = \sum_{i=1}^n p_i l_i$
- ▶ Kod je **optimalen**, če ima najmanjšo možno povprečno dolžino kodnih zamenjav - za kodiranje smo uporabili najmanjše možno število znakov
- ▶ Kod je **ideal**, če je povprečna dolžina kodnih zamenjav enaka entropiji

Teorija

Informacij in sistemov, predavanje 2

ULotric

2. Kodiranje

2.1 Lastnosti kodov

2.2 Kraftova neenakost

2.3 Shannonov prvi teorem

3. Stiskanje


3.1 Shannonov kod

3.2 Fanojev kod

- ▶ osnovnim simbolom lahko priredimo poljubne kodne zamenjave
- ▶ vse kodne zamenjave niso uporabne
- ▶ singularni kodi: različnim znakom je prirejena ista kodna zamenjava
- ▶ nesingularnost ni dovolj: ne vemo kje se znak začne in kje konča
- ▶ Primeri kodov ($A = \{s_1, s_2, s_3\}$, $B = \{0, 1\}$):

A	$p(s_i)$	Kod 1	Kod 2	Kod 3	Kod 4	Kod 5
s_1	0,5	00	0	1	0	0
s_2	0,3	01	1	10	10	0
s_3	0,2	10	01	100	11	1
L		2	1.2	1.7	1.5	1

Razvrstitev kodov:



- ▶ Kod je **enakomeren**, če je dolžina vseh kodnih zamenjav enaka.
- ▶ Kod je **enoznačen**, če lahko poljuben niz znakov dekodiramo na en sam način.
- ▶ Kod je **trenuten**, če lahko osnovni znak dekodiramo takoj, ko sprejmemo celotno kodno zamenjavo. To velja le, če kod ne vsebuje kodne zamenjave, ki bi bila predpona kakšni drugi kodni zamenjavi.

2. Kodiranje

2.1 Lastnosti kodov

2.2 Kraftova neenakost

2.3 Shannonov prvi teorem

3. Stiskanje

3.1 Shannonov kod

3.2 Fanojev kod

- ▶ Kodno drevo: vsako vozlišče ima največ toliko vej kot je različnih znakov v abecedi B . Veje vodijo do naslednjih vozlišč
- ▶ Vozlišča, ki predstavljajo kodne zamenjave označimo z debelo piko
- ▶ Primeri kodnih dreves za prejšnjo tabelo

Teorija

Informacij
in sistemov,
predavanje
2

ULotric

2.
Kodiranje

2.1
Lastnosti
kodov

2.2
Kraftova
neenakost

2.3
Shannonov
prvi teorem

3. Stiskanje


3.1
Shannonov
kod

3.2 Fanojev
kod

- Za dolžine kodnih zamenjav $\{l_1, \dots, l_n\}$ in r znaki kodirne abecede obstaja trenutni kod, če in samo če velja

$$\sum_{i=1}^n r^{-l_i} \leq 1$$

- Primer: enakomerni kod za n znakov, $B = \{0, 1\}$:
 $n2^{-l} \leq 1 \rightarrow n \leq 2^l$, $l = 5 \rightarrow n = 32$ - število različnih kodnih zamenjav, ki jih lahko tvorimo iz 5 znakov
- Skica dokaza s kodnim drevesom:



$$H_r(X) \leq L \rightarrow \frac{H(X)}{\log r} \leq L$$

- ▶ Dokažimo: $H(X) - L \log r \leq 0$ (uporabimo tangento na logaritem in Kraftovo neenakost)
- ▶ Najkrajše povprečne kodne zamenjave imamo, če je $H_r(X) = L \rightarrow l_i = -\log_r p_i$
- ▶ zgornje je res samo, če je za vsak i l_i celo število, drugače $l_i = \lceil -\log_r p_i \rceil$
- ▶ kljub zaokrožitvi imajo bolj verjetni znaki krajše kodne zamenjave

2.3 Povprečna dolžina zamenjav in entropija 2

Teorija
Informacij
in sistemov,
predavanje
2

ULotric

2.
Kodiranje

2.1
Lastnosti
kodov

2.2
Kraftova
neenakost

2.3
Shannonov
prvi teorem

3. Stiskanje

3.1
Shannonov
kod

3.2 Fanojev
kod

$$L < H_r(X) + 1 \rightarrow L < \frac{H(X)}{\log r} + 1$$

- ▶ Dokaz za zgornjo mejo (upoštevamo zaokrožitev navzgor)
- ▶ **omejitev povprečne dolžine kodnih zamenjav**

$$H_r(X) \leq L < H_r(X) + 1$$

$$\frac{H(X)}{\log r} \leq L < \frac{H(X)}{\log r} + 1$$

Kod je **gospodaren**, če je L znotraj zgornjih mej.

- ▶ **učinkovitost koda**

$$\eta = \frac{H(x)}{L \log r}, \quad 0 < \eta \leq 1$$

- ▶ Prva ideja: krajše kodne zamenjave za bolj verjetne znake (pravkar obdelali)
- ▶ Druga ideja: združevanje znakov v večje, sestavljene znake in kodiranje sestavljenih znakov
 - ▶ $(X, X, \dots, X) = X^n, H(X^n) = nH(X)$
 - ▶ $H(X^n) \leq L_n < H(X^n) + 1 \rightarrow nH(X) \leq L_n < nH(X) + 1$
 - ▶ $H(X) \leq L_n/n < H(X) + 1/n$
 - ▶ zgornja meja povprečne dolžine kodne zamenjave na znak L_n/n se v limiti $n \rightarrow \infty$ približuje $H(X)$
- ▶ Teorem: Za nize neodvisnih znakov dolžine n (X^n) obstajajo kodi za katere velja

$$\lim_{n \rightarrow \infty} \frac{L_n}{n} = H(X)$$

pri čemer je $H(X)$ entropija vira X .

- ▶ Posledica: z večanjem n se zgornja meja lahko poljubno približa entropiji
- ▶ Cena: kompleksno kodiranje in zakasnitev pri dekodiranju

- ▶ znake razvrstimo po padajočih verjetnostih
- ▶ število znakov v vsaki kodni zamenjavi določimo iz enačbe $l_k = \lceil -\log_r p_k \rceil$
- ▶ za vse simbole izračunamo kumulativne verjetnosti $P_k = \sum_{i=1}^{k-1} p_i$
- ▶ P_k pretvorimo v bazo r . Kodno zamenjavo predstavlja prvih l_k znakov necelega dela števila

- ▶ Primer 1: $\{0.5, 0.25, 0.125, 0.125\}$
 $L = 7/4, H = 7/4, \eta = 1$
- ▶ Primer 2: $\{0.39, 0.19, 0.16, 0.13, 0.13\}$
 $L = 2.61, H = 2.17, \eta = 0.83$
- ▶ Kod ni najboljši: za verjetnosti $\{0.9, 0.1\}$ dobimo namesto kodnih zamenjav dolžine 1, eno dolžine 1 in drugo dolžine 4!

- ▶ znake razvrstimo po padajočih verjetnostih
- ▶ Znake razdelimo v r čim bolj enako verjetnih skupin
- ▶ Vsaki skupini priredimo enega od r znakov kodne abecede
- ▶ Deljenje ponovimo na vsaki od skupin. Ponavljamo, dokler je mogoče
- ▶ Primer 1: $\{0.5, 0.25, 0.125, 0.125\}$,
 $L = 7/4, H = 7/4, \eta = 1$
- ▶ Primer 2: $\{0.39, 0.19, 0.16, 0.13, 0.13\}$,
 $L = 2.26, H = 2.17, \eta = 0.96$