OSNOVE UMETNE INTELIGENCE

2022/23

uvod v predmet umetna inteligenca uvod v strojno učenje

Osnove umetne inteligence

Izvajalci

nosilec:

Zoran Bosnić

2. nadstropje, R2.17 (kabinet)

asistenti:

Jure Žabkar

Aleš Papič

Matej Pičulin

Marko Zeman

Bojan Žunkovič

(3. nadstropje, R3.54 - LUI)

(2. nadstropje, R2.25 - LKM)



Cilji predmeta

- kaj je umetna inteligenca?
 - kaj si prizadeva?
 - kakšna je definicija?
 - kako dobro nam uspeva doseči te cilje?
 - kakšne so posledice v filozofiji, psihologiji, etiki?
- kaj vse lahko delamo z metodami umetne inteligence?
 - vrste problemov
 - načini reševanja problemov
- kako razumeti medije, literaturo in objave s področja umetne inteligence?



Obveznosti predmeta



sprotno delo:

domače naloge - kvizi na učilnici, vezani na predavanja in vaje. Potrebno je pozitivno (>= 50%) opraviti vsaj 4 od 5 domačih nalog. Za vsak kviz so na razpolago 3 poskusi.

končni izpit:
 pisni izpit. Pogoj za pristop k izpitu so opravljene DN.

KONČNA OCENA pri predmetu je enaka oceni končnega izpita.

Literatura

[AIMA]

S. Russell, P. Norvig, Artificial Intelligence: A Modern Approach, Third edition, Pearson Education, Prentice-Hall 2010, ISBN: 0136042597.

• [PPAI]

I. Bratko, Prolog Programming for Artificial Intelligence, 4th edition, Pearson Education, Addison-Wesley 2011, ISBN: 0201403757.

• [PUI]

I. Bratko, Prolog in umetna inteligenca, Založba FE in FRI, ponatis 2011.

• [SU]

I. Kononenko, Strojno učenje, Založba FE in FRI, 2005.

• [MLDM]

Kononenko, Igor, and Matjaz Kukar. Machine learning and data mining. Horwood Publishing, 2007.

• [IS]

I. Kononenko, M. Robnik Šikonja, Inteligentni sistemi. Založba FE in FRI, 2010.



Termini predavanj in vaj

- pričetek laboratorijskih vaj:
 - 17. 10. po urniku
- prazniki (predavanja odpadejo):
 - 1. 11. 2022
 - 27. 12. 2022
- nadomeščanja:
 - 25. 10. 2022 odpade, nadomeščamo v terminu 19. 10. 21. 10.
 - 6. 12. 2022 odpade, nadomeščamo v terminu 30. 11. 2. 12.



Kaj je to "umetna inteligenca"?



Umetna inteligenca?





Artificial intelligence (AI) promises to transform the media and entertainment business – impacting everything from content creation to the consumer experience. ... "Through techniques such as image recognition and speech-to-text transcription, metadata tagging is the most widespread application of AI so far. Sep 7, 2018



How artificial intelligence is transforming the media industry

https://www.technologyrecord.com > Article > how-artificial-intelligence-is-t...

Google's AI Can Make Its Own AI Now. Artificial intelligence is advanced enough to do some pretty complicated things: read lips, mimic sounds, analyze photographs of food, and even design beer. ... The project is called AutoML, and it's designed to come up with better machine-learning software than humans can.

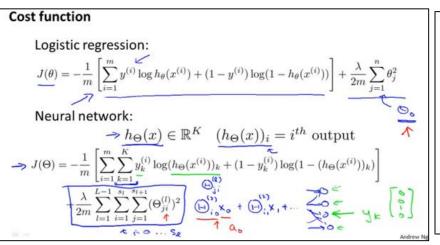


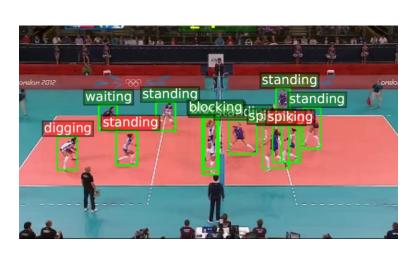
Facebook's experiment isn't the only time that **artificial intelligence** has invented new forms of **language**. Earlier this year, Google revealed that the **AI** it uses for its Translate tool had created its **own language**, which it would translate things into and then out of. Jul 31, 2017

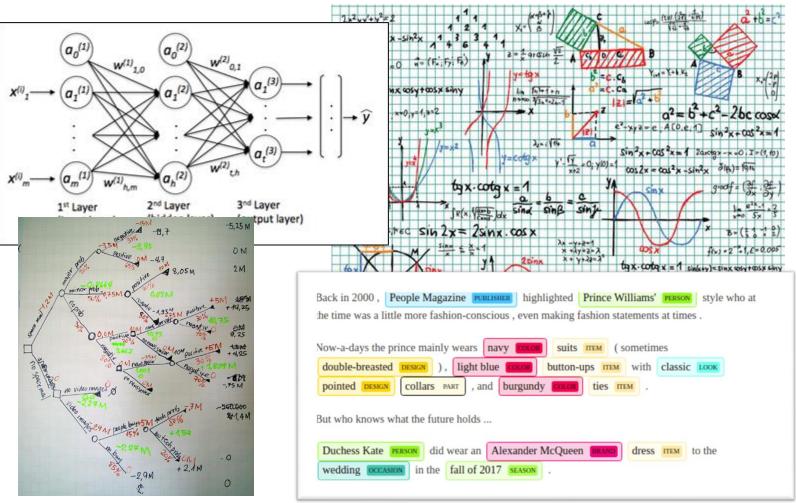
Facebook's artificial intelligence robots shut down after they ... https://www.independent.co.uk > life-style > gadgets-and-tech > news > face...



Umetna inteligenca... ...zares?







Vsebina predmeta

- uvod, definicija umetne inteligence
- strojno učenje:
 - problemski prostor, hipoteze, ocenjevanje učenja
 - gradnja odločitvenih dreves
 - učenje iz šumnih podatkov, rezanje
 - manjkajoči atributi, regresija, naivni Bayes
- reševanje problemov kot preiskovanje grafov
 - neinformirani preiskovalni algoritmi
 - informirani preiskovalni algoritmi
 - lokalno preiskovanje
 - grafi AND/OR, nedeterministično okolje
- igranje iger
- planiranje, razporejanje opravil
- predstavitev negotovega znanja, Bayesovske mreže
- avtomatsko sklepanje



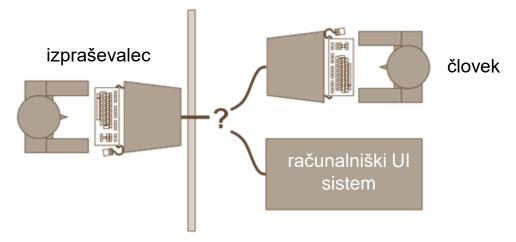
Kaj je umetna inteligenca?



- cilj umetne inteligence: razumeti in zgraditi inteligentne sisteme na osnovi razumevanja človeškega <u>razmišljanja</u>, <u>sklepanja</u>, <u>učenja</u> in <u>komuniciranja</u> (izvajanja dejanj, pojasnjevanja, komentiranja)
- različne definicije, ki izvirajo iz različnega pojmovanja človeške inteligence in cilja, ki ga pričakujemo od računalniškega sistema
- težava: definicija inteligence?
 - ali je vse, kar počne človek, inteligentno (refleksi, nekonsistentnost, napake, učinkovitost)?
 - ali zasledovati modeliranje človeka ali modeliranje ideala (princip racionalnosti optimalnosti "doing the right thing")
- umetna inteligenca:
 - sistemi, ki se vedejo/razmišljajo kot človek/racionalno
 - kako je s kreativnostjo, čustvi, zavestjo?
- velika medijska pokritost ("Al will conquer the world" (!@#!))

Turingov test

- sistem, ki se "vede kot človek"
- **praktični preizkus** (the immitation game), ki ga predlaga Turing (1950) za testiranje, ali je sistem dosegel stopnjo inteligence, primerljivo s človekom
- računalnik "opravi" preizkus, če človeški izpraševalec po računalnikovih odgovorih na zastavljena vprašanja ne more ugotoviti, ali odgovore podaja človek ali računalnik



- ideja napeljuje na sposobnosti inteligentnih sistemov: obdelava naravnega jezika, predstavitev znanja, avtomatsko sklepanje, strojno učenje, računalniški vid, robotika
- problem: testa ni možno reproducirati ali podvreči matematični analizi

Zgodovina Ul

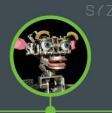
A.I. TIMELINE











1950

TURING TEST

Computer scientist test for machine intelligence. If a machine can trick humans into thinking it and engineering of is human, then it has intelligence

1955

A.I. BORN

Term 'artificial Alan Turing proposes a intelligence' is coined by computer scientist. John McCarthy to describe "the science making intelligent machines"

1961

UNIMATE

First industrial robot, Unimate, goes to work developed by Joseph at GM replacing humans on the assembly line

1964

Pioneering chatbot Weizenbaum at MIT holds conversations with humans

1966

SHAKEY

The 'first electronic person' from Stanford, Shakey is a generalpurpose mobile robot that reasons about

A.I.

WINTER

Many false starts and dead-ends leave A.I. out in the cold

1997

DEEP BLUE

Deep Blue, a chessplaying computer from introduces KISmet, an IBM defeats world chess emotionally intelligent champion Garry Kasparov

1998

Cynthia Breazeal at MIT robot insofar as it to people's feelings



















1999

Sony launches first consumer robot pet dog autonomous robotic AiBO (Al robot) with skills and personality that develop over time and clean homes

2002

First mass produced vacuum cleaner from iRobot learns to navigate interface, into the

2011

Apple integrates Siri, an intelligent virtual assistant with a voice iPhone 4S

2011

WATSON

IBM's question answering computer Watson wins first place on popular \$1M prize television quiz show

2014

Eugene Goostman, a chatbot passes the Turing Test with a third of judges believing Eugene is human

2014

Amazon launches Alexa, Microsoft's chatbot Tay an intelligent virtual assistant with a voice interface that completes inflammatory and shopping tasks

2016

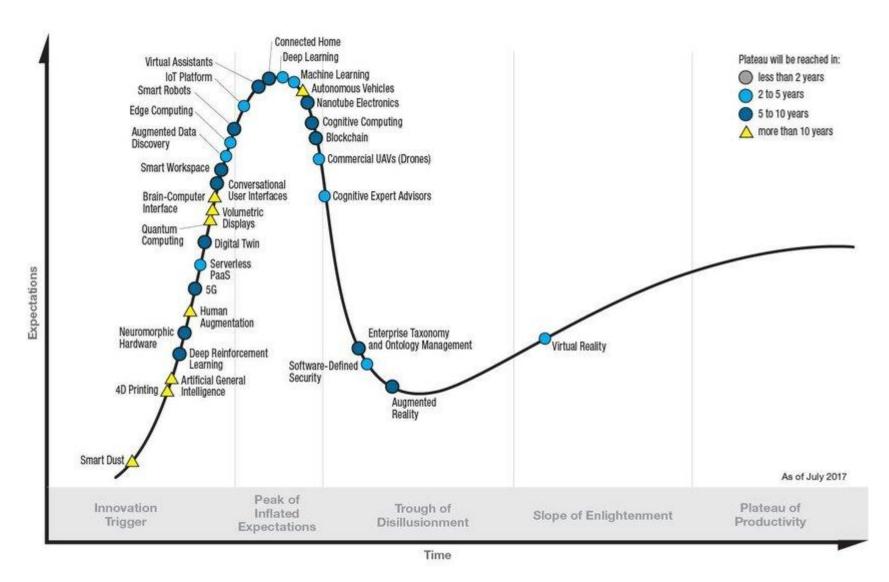
goes rogue on social media making offensive racist comments

2017

ALPHAGO

Google's A.I. AlphaGo beats world champion Ke Jie in the complex board game of Go, notable for its vast number (2170) of possible positions

Zgodovina UI



Cilj umetne inteligence



- razumeti in zgraditi "inteligentne" sisteme, na osnovi razumevanja človeškega
 razmišljanja, sklepanja, učenja, izvajanja dejanj, pojasnjevanja, komentiranja
- težava: definicija inteligence?

izvajanje pogovora z osebo

analiza in sinteza jezika

In česa še UI ne zna...? Kaj danes znamo z UI? avtonomna (robotska) vozila razlaga odločitev robotska opravila (pospravljanje pomivalnega stroja?) odločanje po moralnih načelih razpoznavanje govora (klicni centri, pametni telefoni, ...) občutenje empatije, simpatije in drugih čustev igranje iger (šah - Deep Blue in Kasparov 1997), kreativnost popolno nadomeščanje človeških delavcev namizni tenis, karte) načrtovanje logistike (porabe sredstev) zavedanje (izdelava profila na FB?) detekcija neželene elektronske pošte robotika (Roomba, raziskovanje vesolja) A.I. of the PAST... A.I. of TOMORROW. strojno prevajanje nakupovanje živil za naslednji teden

iskanje in izpeljava novih matematičnih dokazov podajanje ustreznih nasvetov na pravnem področju prevajanje med dvema jezikoma v realnem času

Osnove umetne inteligence

I. STROJNO UČENJE

(*machine learning*) in odkrivanje zakonitosti v podatkih (podatkovno rudarjenje, *data mining, knowledge discovery in databases*)

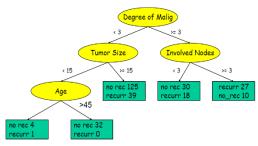
II. REŠEVANJE PROBLEMOV

iskanje rešitev v problemskem prostoru, igranje iger

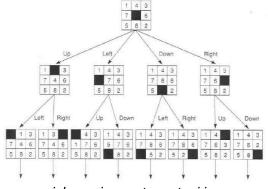
III. PLANIRANJE, RAZPOREJANJE OPRAVIL izdelava načrta (plana) akcij za doseganje cilja

IV. SKLEPANJE

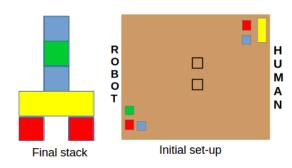
avtomatsko sklepanje (*reasoning, inference*), uporaba predstavitev znanj

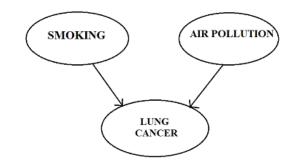


strojno učenje – odločitveno drevo za napovedovanje ponovitve raka na dojki



preiskovanja prostora stanj igre s ploščicami

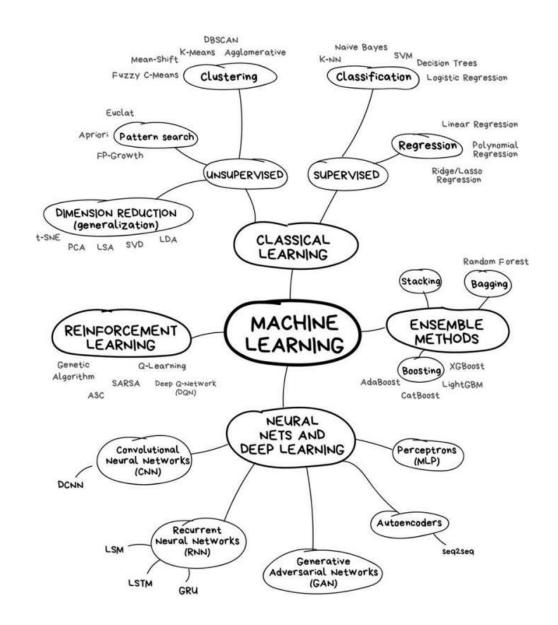




I. STROJNO UČENJE

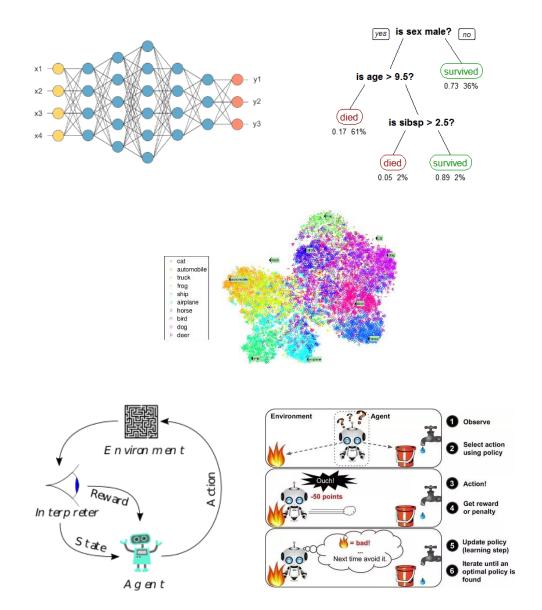
Strojno učenje

- angl. machine learning
- je področje umetne inteligence, ki raziskuje, kako se lahko algoritmi samodejno izboljšujejo ob pridobivanju izkušenj
- naloge: analiza učnih podatkov, gradnja modela, (napovedovanje)
- zakaj takoj ne vključiti vsega znanja v program?
 - razvijalci programske opreme ne morejo predvideti vseh možnih problemskih situacij,
 - razvijalci ne morejo predvideti sprememb okolja skozi čas (prilagodljivost)
 - razvijalci ne znajo sprogramirati agenta z znanjem (npr. razpoznava obrazov?)



Vrste učenja

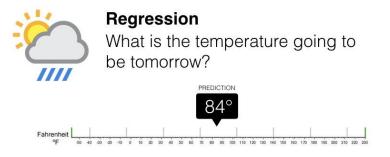
- nadzorovano učenje (angl. supervised learning): učni primeri so podani kot vrednosti vhodov in izhodov (učni primeri so označeni); učimo se funkcije, ki preslika vhode v izhode (npr. odločitveno drevo)
- nenadzorovano učenje (angl. unsupervised learning): učni primeri niso označeni (nimajo ciljne spremenljivke); učimo se vzorcev v podatkih (npr. gručenje)
- spodbujevano učenje (angl. reinforcement learning): inteligentni agent se uči iz zaporedja nagrad in kazni



Nadzorovano učenje

- podana: množica učnih primerov $(x_1, y_1), (x_2, y_2), ..., (x_N, y_N),$ kjer je vsak y_j vrednost neznane funkcije y = f(x)
- naloga: najdi funkcijo h, ki je najboljši približek funkciji f
- x_i so atributi (vrednost ali vektor)
- funkcijo h imenujemo hipoteza
- ločimo dve vrsti problemov:
 - če je y_j diskretna (kategorična) spremenljivka
 - → klasifikacijski problem
 - če je y_i zvezna spremenljivka
 - → regresijski problem

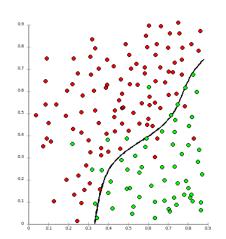


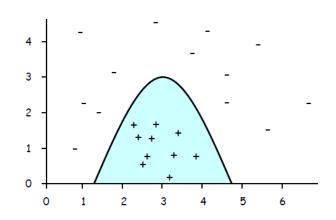


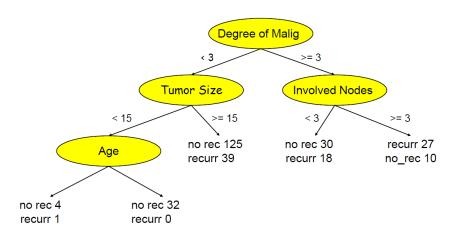
Vrste problemov

klasifikacija:

- y pripada končnem naboru vrednosti (je diskretna spremenljivka)
- npr. $y \in \{u\check{z}itna, strupena\}, y \in \{sonce, obla\check{c}no, de\check{z}\}, y \in \{zdrav, bolan\}$
- y imenujemo razred (angl. class)
- primeri:
 - napovedovanje vremena iz podatkov prejšnjih let
 - diagnosticiranje novih pacientov na osnovi znanih diagnoz za stare paciente
 - klasifikacija neželene elektronske pošte
 - napovedovanje vračila kredita





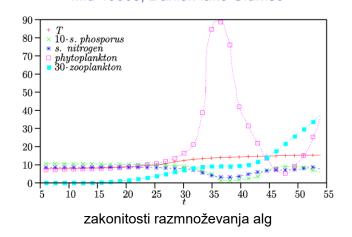


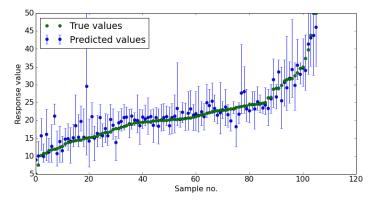
Vrste problemov

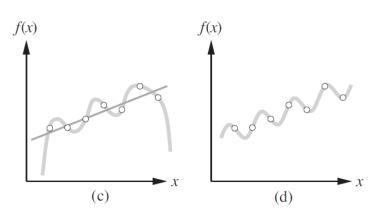
regresija:

- y je število (običajno $y \in \mathbb{R}$, je zvezna spremenljivka)
- npr. y je temperatura,
- y imenujemo označba (angl. label)
- primeri:
 - napovedovanje razmnoževanja alg
 - medicinska diagnostika
 - napovedovanje vremena
 - napovedovanje koncentracije ozona
 - napovedovanje gibanja cen delnic

Mid 1980s, Danish lake Glumso







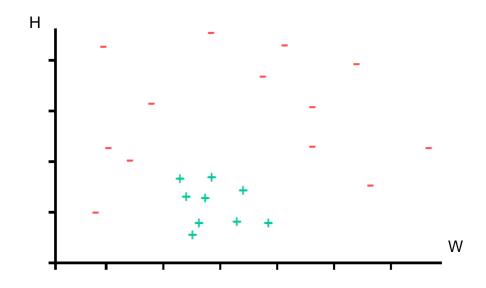
Atributna predstavitev podatkov

- učna množica: čakanje na prosto mesto v restavraciji
- ciljna spremenljivka: čakamo (T) ali ne čakamo (F)

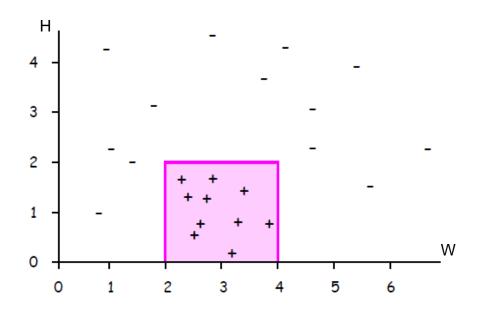
| Example | Attributes | | | | | | | | | | Target |
|----------|------------|-----|-----|-----|------|---------------|------|-----|---------|-------|----------|
| | Alt | Bar | Fri | Hun | Pat | Price | Rain | Res | Type | Est | WillWait |
| X_1 | T | F | F | T | Some | \$\$\$ | F | T | French | 0–10 | T |
| X_2 | T | F | F | T | Full | \$ | F | F | Thai | 30–60 | F |
| X_3 | F | T | F | F | Some | \$ | F | F | Burger | 0–10 | T |
| X_4 | T | F | T | T | Full | \$ | F | F | Thai | 10–30 | T |
| X_5 | T | F | T | F | Full | <i>\$\$\$</i> | F | T | French | >60 | F |
| X_6 | F | T | F | T | Some | <i>\$\$</i> | T | T | Italian | 0–10 | T |
| X_7 | F | T | F | F | None | \$ | T | F | Burger | 0–10 | F |
| X_8 | F | F | F | T | Some | <i>\$\$</i> | T | T | Thai | 0–10 | T |
| X_9 | F | T | T | F | Full | \$ | T | F | Burger | >60 | F |
| X_{10} | T | T | T | T | Full | <i>\$\$\$</i> | F | T | Italian | 10–30 | F |
| X_{11} | F | F | F | F | None | \$ | F | F | Thai | 0–10 | F |
| X_{12} | T | T | T | T | Full | \$ | F | F | Burger | 30–60 | T |

Primer: gobe

- razpoznavanje užitnih gob
- atributa (x): W (width) in H (height)
- razred (y): strupena (-), užitna (+)



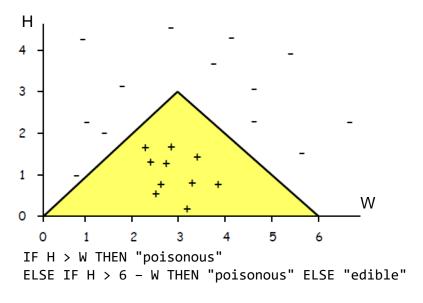


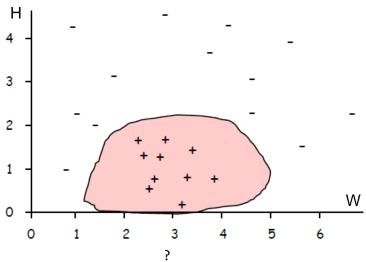


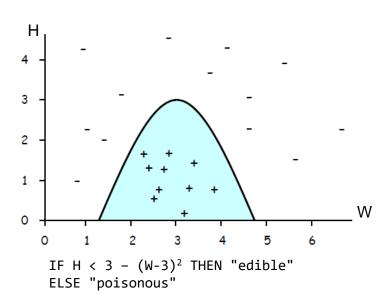
IF W>2 and W<4 and H<2
THEN "edible" ELSE "poisonous"</pre>

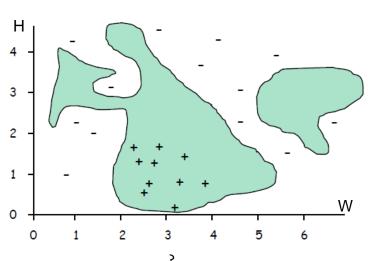
Primer: gobe

• ali pa ...



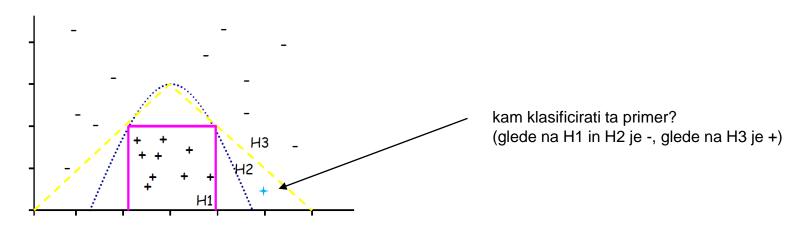






Primer: gobe

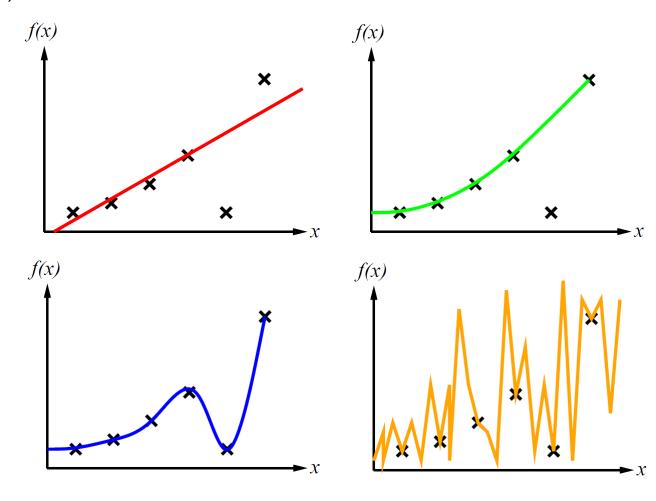
- prostor hipotez vsebuje več hipotez
- vse prikazane hipoteze so konsistentne z učno množico
- dobra hipoteza je dovolj splošna (angl. general), kar pomeni, da pravilno napoveduje vrednost y za nove (še nevidene) primere



- kako izbrati primerno hipotezo? Princip Ockhamove britve (Ockham's razor) (William of Ockham, 1320, angleški filozof):
 - prava hipoteza je najbolj preprosta hipoteza
 - Entities should not be multiplied unnecessarily
 - Given two explanations of the data, all other things being equal, the simpler explanation is preferrable.

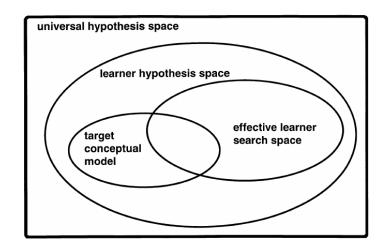
Primer

 podoben problem z izbiro hipoteze imamo tudi pri regresijskih problemih (iskanje funkcije, ki opisuje podane točke)



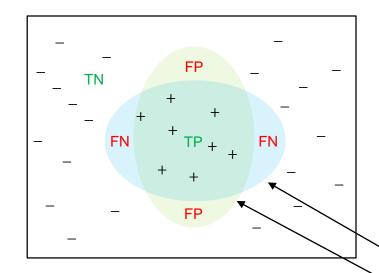
Prostor hipotez

- denimo, da imamo
 - binarno klasifikacijo
 - n binarnih atributov
- sledi:
 - \rightarrow 2ⁿ različnih učnih primerov
 - → 2^{2ⁿ} hipotez (denimo, da lahko hipotezo opišemo s tabelo napovedi za vse primere)
- primer:
 - za 10 atributov izbiramo med 10³⁰⁸ možnimi hipotezami
 - za 20 atirbutov izbiramo med 10^{300.000} možnimi hipotezami
 - v resnici: hipotez je še več, izračunavajo lahko isto funkcijo
- potrebujemo:
 - algoritme za gradnjo "dobrih" hipotez
 - metode za ocenjevanje hipotez / ocenjevanje učenja
 - zavedanje o pristranosti hipotez



Evalviranje hipotez

- pomembni kriteriji:
 - konsistentnost hipotez s primeri (učnimi)
 - splošnost (točnost za nevidene primere)
 - razumljivost (interpretability, comprehensibility) hipotez
- ocenjevanje uspešnosti pri klasifikaciji na podlagi njihove točnosti:
 - točnost na učnih podatkih? (pristranost hipotez?)
 - točnost na testnih podatkih?
 - točnost na novih (še nevidenih) podatkih?



TP – pravilno pozitivno klasificirani primeri (angl. true positive)

TN – pravilno negativno klasificirani primeri (angl. true negative)

FP – napačno pozitivno klasificirani primeri (angl. false positive)

FN – napačno negativno klasificirani primeri (angl. false negative)

klasifikacijska točnost (angl. classification accuracy):

$$CA = \frac{TP + TN}{TP + TN + FP + FN} = \frac{TP + TN}{N}$$

pravi (ciljni, neznani) pojem

Izpitna naloga

1. izpitni rok, 30. 1. 2018

3. NALOGA:

Podan je primer učenja iz primerov z atributoma A in B ter razredom C. Atribut A in razred sta binarna, atribut B pa lahko zavzame tri vrednosti. Učno množico primerov, ki smo jih zajeli in v katerih ni šuma, prikazuje tabela na desni. Denimo, da vemo, da pravo odvisnost med atributi in razredom izraža funkcija $C = IF (AB^2) < (A+B) THEN \ 1 \ ELSE \ 0$. Istočasno pa se z dvema različnima algoritmoma za učenje iz primerov naučimo naslednjih dveh hipotez:

H1:
$$C = A + 1.5 \cdot B - AB - 0.5 \cdot B^2$$

H2: $C = \min(A + B.1) - \min(A.B)$

Odgovori na naslednja vprašanja:

- a) Katera od podanih hipotez je bolj splošna? Kaj to pomeni?
- b) Katera od podanih hipotez ima višjo klasifikacijsko točnost na učni množici?
- c) Kakšna je razlika med nadzorovanim in nenadzorovanim učenjem? S katerim imamo opravka pri zgornji nalogi? Podaj primer problema nadzorovanega in nenadzorovanega učenja iz prakse.
- d) Kaj je to binarizacija atributa in zakaj je koristna? Podaj primer binarizacije atributa B.

