

OSNOVE UMETNE INTELIGENCE


2022/23

*planiranje z regresiranjem ciljev
verjetnostno sklepanje z bayesovskimi mrežami*

Pridobljeno znanje s prejšnjih predavanj

- **igranje iger med nasprotnikoma**
 - dva igralca, MIN in MAX, izmenične poteze v igralnem drevesu
 - igralca vplivata na vrednost **kriterijske funkcije** v listih
 - **algoritem MINIMAX** določa optimalno strategijo, če igralca igrata optimalno
 - **rezanje alfa-beta** vrne isto zaporedje potez kot bi algoritem MINIMAX s to razliko, da ne upošteva vej, ki ne vplivajo na končno odločitev
 - alfa, beta, prenašanje vrednosti v globino, posodabljanje vrednosti navzgor
 - rezultat rezanja odvisen od vrstnega reda vozlišč, časovna zahtevnost?
- **planiranje**
 - začetno stanje, akcije, ciljno stanje, akcije imajo: predpogoje, učinke, omejitve
 - jezika STRIPS, PDDL
 - klasično **preiskovanje** prostora stanj (kombinatorična eksplozija, uporaba nekoristnih akcij)
 - planiranje s **sredstvi in cilji** (vzvratno izpolnjujemo predpogoje, da lahko izvedemo akcijo)
 - planiranje z regresiranjem ciljev

Pregled



III. PLANIRANJE in razporejanje opravil


- predstavitev problema
- planiranje s "klasičnim" preiskovanjem prostora stanj
- planiranje s sredstvi in cilji
- planiranje z regresiranjem ciljev
- razporejanje opravil

IV. VERJETNOSTNO SKLEPANJE z bayesovskimi mrežami

- definicija
- izračun verjetnosti dogodkov
- vprašanja pri verjetnostnem sklepanju
- odvisnosti v bayesovski mreži
- neodvisnosti v bayesovski mreži
- ekvivalenca bayesovskih mrež

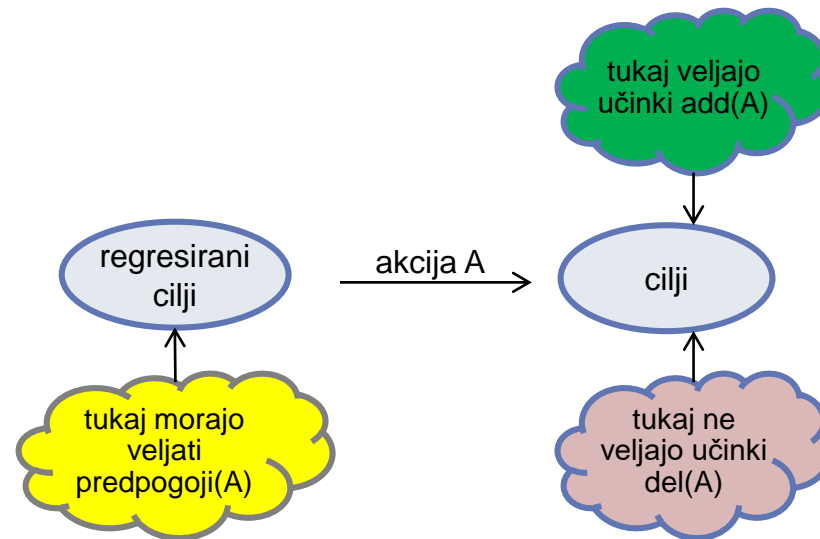
Planiranje z regresiranjem ciljev

- rešitev za Sussmanovo anomalijo
- vzvratno preiskovanje od cilja proti začetnemu stanju (angl. *goal regression through action*)
- drugačna filozofija:
 - *globalno* planiranje, ker algoritem za planiranje obravnava vse cilje hkrati
 - ne obravnavamo samo akcij, ki so *možne*, temveč *najbolj smiselne*
- postopek:
 - izberemo akcijo, ki doseže čim večjo množico izbranih ciljev (upoštevamo torej celo množico ciljev)
 - izračunamo "predhodne" cilje ob uporabi te akcije (= regresiranje ciljev skozi akcijo)
 - analiziramo veljavnost množice ciljev glede na postopek regresiranja
 - analiziramo protislovja v regresirani množici ciljev
 - nadaljujemo z regresiranjem, dokler ne pridemo do ciljev, ki so izpolnjeni v začetnem stanju




Planiranje z regresiranjem ciljev

- postopek regresiranja ciljev



- $\text{regresirani cilji} = \text{cilji} \cup \text{predpogoji}(A) - \text{add}(A)$
- $\text{veljati mora cilji} \cap \text{del}(A) = \emptyset$
- "stanja" pri preiskovanju so **množice ciljev**
- ciljni pogoj:** $\text{regresirani cilji} \subseteq \text{cilji}$ v začetnem stanju
- uporabimo znane preiskovalne algoritme (neinformirani / informirani algoritmi; A^* , heuristika?)

Planiranje z regresiranjem ciljev



- v primeru iz sveta kock velja:
stanje: $[on(c,a), on(a,1), on(b,3), clear(c), clear(2), clear(b), clear(4)]$
cilj: $[on(a,b), on(b,c)]$

- rešitev z regresiranjem ciljev najde optimalno rešitev
move(c,a,2)
move(b,3,c)
move(a,1,b) %plan zaključen, vsi cilji izpolnjeni

- vaja regresiranja:
Regresiraj cilja $C = \{on(a,b), on(b,c)\}$ skozi akcijo $move(a,2,b)$.

$$\begin{aligned} \text{Regresirani cilji} &= C \cup \text{predpogoji}(A) - \text{add}(A) \\ &= \{on(a,b), on(b,c)\} \cup \{clear(a), clear(b), on(a,2)\} - \{on(a,b), clear(2)\} = \\ &= \{on(b,c), clear(a), clear(b), on(a,2)\} \end{aligned}$$

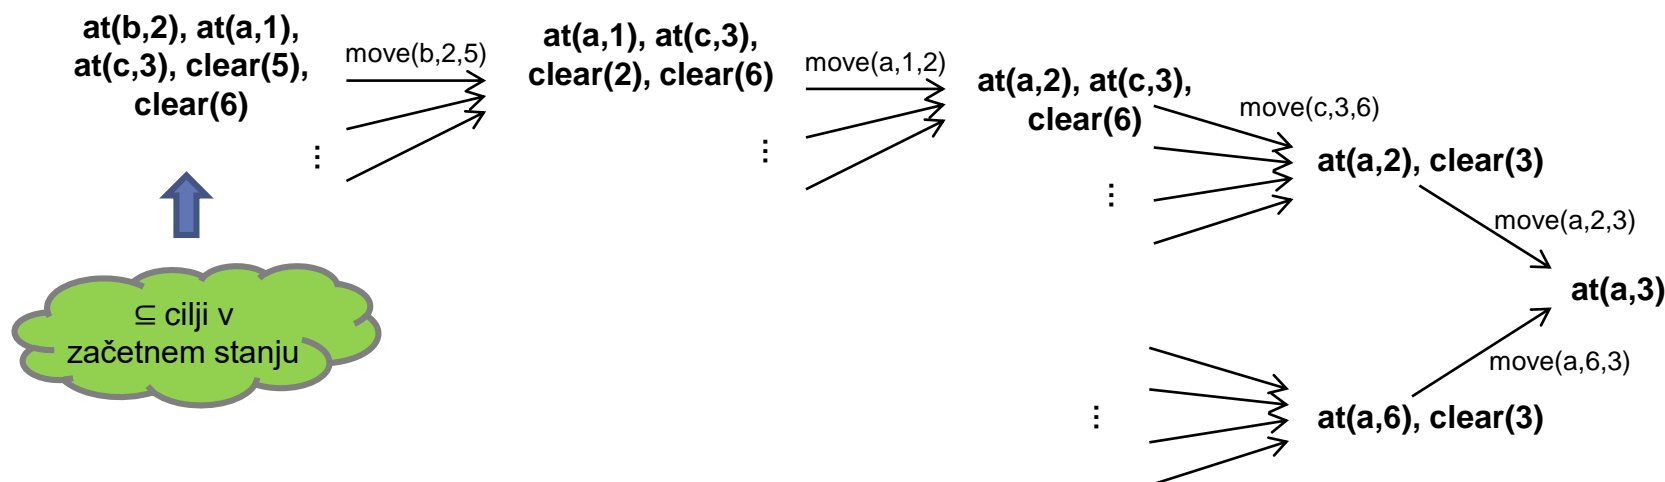
$$\text{Pogoj: } \{on(a,b), on(b,c)\} \cap \{on(a,2), clear(b)\} = \emptyset$$

Planiranje z regresiranjem ciljev

4	5	6
a 1	b 2	c 3


- primer: roboti na pravokotni mreži
- začetno stanje: `[at(a,1), at(b,2), at(c,3), clear(4), clear(5), clear(6)]`
- ciljno stanje: `[at(a,3)]`
- akcija:

	<code>move(Robot, From, To)</code>
predpogoj:	<code>[at(Robot, From), clear(To)]</code>
implicitne omejitve:	<code>[robot(Robot), adjacent(From, To)]</code>
add:	<code>[at(R, To), clear(From)]</code>
del:	<code>[at(Robot, From), clear(To)]</code>



- plan: `move(b,2,5), move(a,1,2), move(c,3,6), move(a,2,3)`

Pregled



III. PLANIRANJE in razporejanje opravil

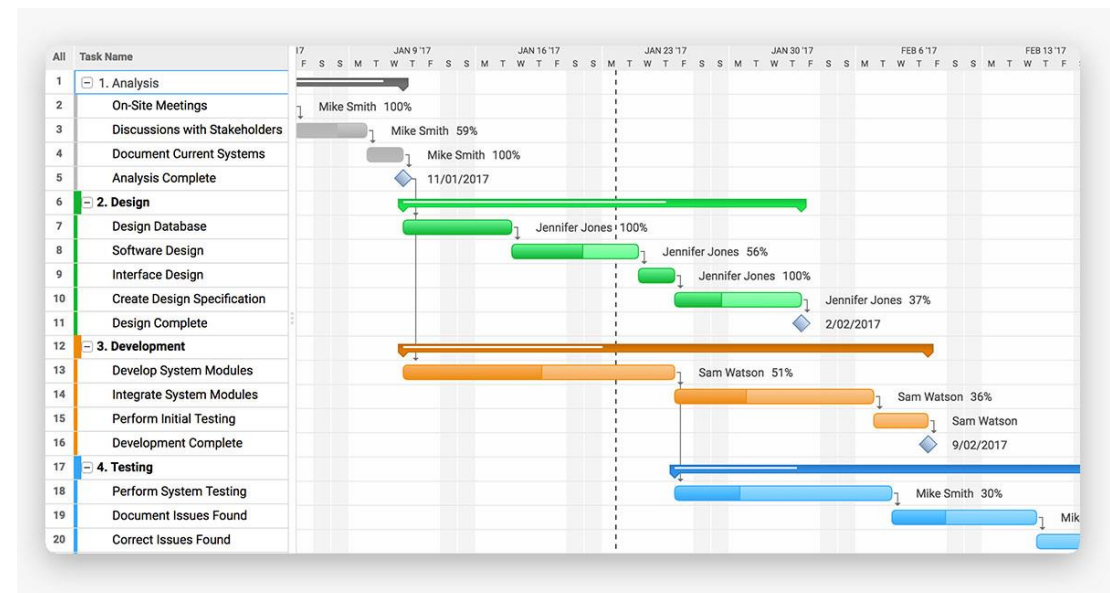
- predstavitev problema
- planiranje s "klasičnim" preiskovanjem prostora stanj
- planiranje s sredstvi in cilji
- planiranje z regresiranjem ciljev
- razporejanje opravil

IV. VERJETNOSTNO SKLEPANJE z bayesovskimi mrežami

- definicija
- izračun verjetnosti dogodkov
- vprašanja pri verjetnostnem sklepanju
- odvisnosti v bayesovski mreži
- neodvisnosti v bayesovski mreži
- ekvivalenca bayesovskih mrež

Planiranje in razporejanje opravil

- do sedaj (klasično planiranje): **kaj narediti** in v kakšnem **vrstnem redu**
- pristopi:
 - planiranje kot preiskovanje prostora stanj
 - planiranje s sredstvi in cilji
 - planiranje z regresiranjem ciljev skozi akcije
- v realnosti imamo številne **dodatne omejitve**:
 - **časovne omejitve** (začetki aktivnosti, trajanja aktivnosti, roki zaključkov)
 - **resursi** (omejeno število procesorjev, kadra, bencina, denarja, surovin, ...)



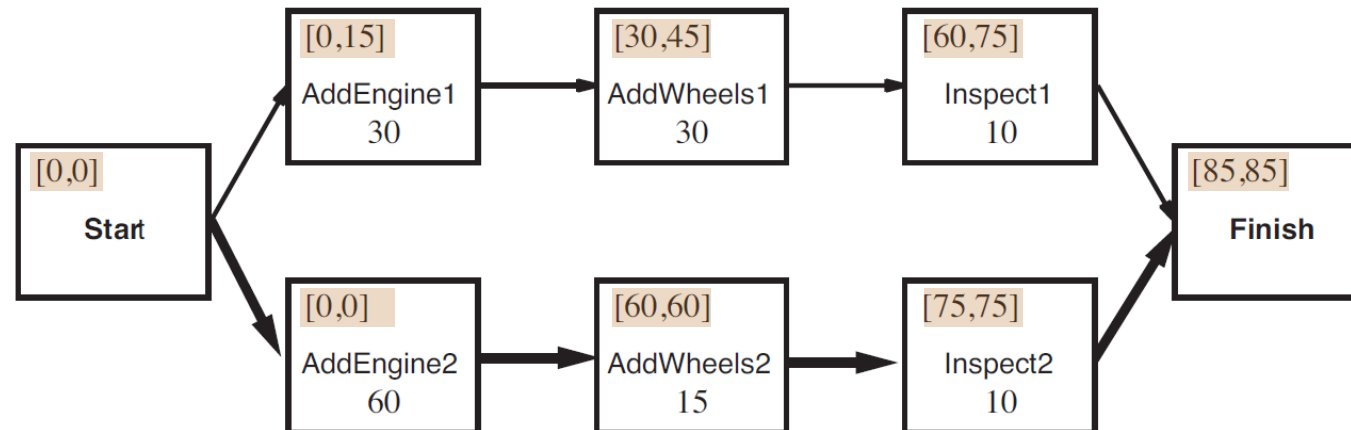
Razporejanje opravil

- delno urejen plan: vrstni red podmnožice aktivnosti je lahko urejen
- razširimo lahko notacijo (PDDL):
 - **Akcija1** < **Akcija2**: pomeni, da se mora Akcija1 zgoditi pred Akcijo2
 - **Resources** podaja števila razpoložljivih resursov
 - **DURATION** opredeljuje trajanje posamezne akcije
 - **CONSUME** opredeljuje (trajno) porabo določene količine resursov
 - **USE** opredeljuje (začasno) zasedenost količine resursov med izvajanjem akcije

```
Jobs (AddEngine1 < AddWheels1 < Inspect1,  
      AddEngine2 < AddWheels2 < Inspect2 )  
Resources (EngineHoists(1), WheelStations(1), Inspectors(2), LugNuts(500))  
  
Action (AddEngine1 , DURATION:30,  
        USE:EngineHoists(1))  
Action (AddEngine2 , DURATION:60,  
        USE:EngineHoists(1))  
Action (AddWheels1 , DURATION:30,  
        CONSUME:LugNuts(20), USE:WheelStations(1))  
Action (AddWheels2 , DURATION:15,  
        CONSUME:LugNuts(20), USE:WheelStations(1))  
Action (Inspect i, DURATION:10,  
        USE:Inspectors (1))
```

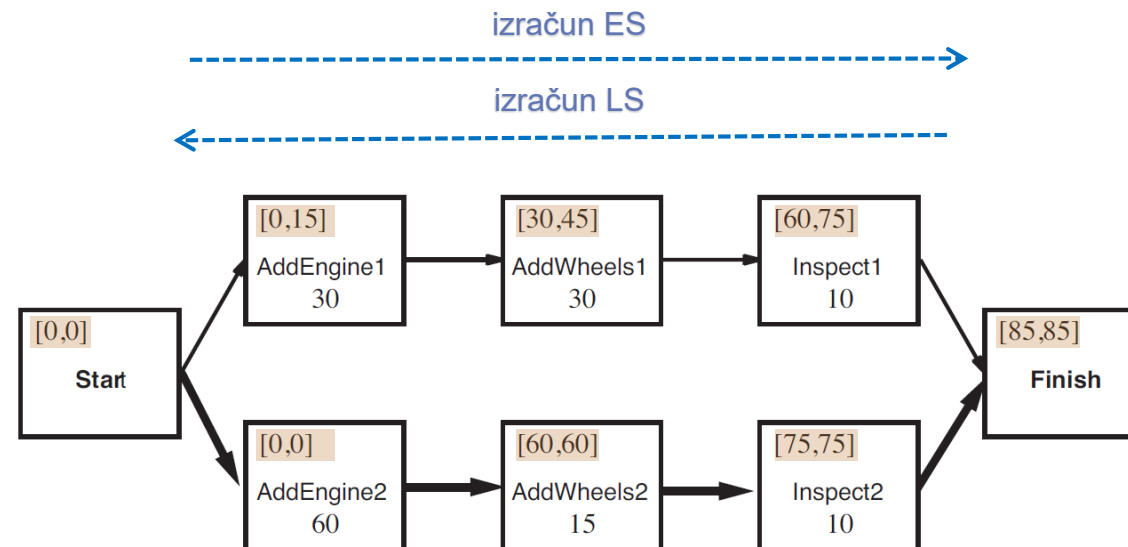

Razporejanje opravil

- za začetek: samo časovne omejitve
- **metoda kritične poti**
 - kritična pot: pot, ki je najdaljša in določa dolžino trajanja celotnega plana (krajšanje vzporednih poti ne vpliva na trajanje plana)
 - vsaki akciji priredimo par **[ES, LS]**:
 - **ES** – najbolj zgodnji možen začetek (angl. *Earliest Start*)
 - **LS** – najbolj pozen možen začetek (angl. *Latest Start*)



Razporejanje opravil


$$\begin{aligned} ES(Start) &= 0 \\ ES(B) &= \max_{A \prec B} [ES(A) + Duration(A)] \\ LS(Finish) &= ES(Finish) \\ LS(A) &= \min_{A \prec B} [LS(B) - Duration(A)] \\ rezerva (slack) &= LS - ES \end{aligned}$$



- časovna zahtevnost algoritma: $O(Nb)$, N – število akcij, b – faktor vejanja

Razporejanje opravil

- dodatno: upoštevanje tudi resursov
- uvede **omejitev**, da se aktivnosti, ki potrebujeta iste resurse, ne smeta prekrivati



- sprememba časovne zahtevnosti: $O(Nb) \rightarrow$ NP-težek problem (!)
- primer izziv iz leta 1963 nerešen 23 let:
 - resursi: 10 strojev, 10 nalog, 100 akcij
 - preizkušene metode: simulirano ohlajanje, tabu search, razveji in omeji, ...
- primerna heuristika: algoritem **najmanjše časovne rezerve** (angl. *minimum slack algorithm*)
 - na vsaki iteraciji dodeli **najbolj zgodnji možen začetek** akciji, ki ima **izpolnjene vse predhodnike** in ima **najmanj časovne rezerve**,
 - nato posodobi [ES in LS] za celotni graf in ponovi.

Razporejanje opravil

- Kakšen je rezultat simulacije algoritma najmanjše časovne rezerve na obravnavanem problemu?
- Ali je rešitev enaka optimalni? Zakaj?
- Kako upoštevati omejitve v zaporedju akcij pri pristopih za planiranje?
- Kako upoštevati omejitve v omejenem številu resursov?



Primer izpitne naloge

- 3. izpit, 2. 9. 2019

2. NALOGA (10t):

Podan je naslednji delno urejen plan s trajanji akcij, njihovimi odvisnostmi in uporabo resursov:

```
Jobs (Zajtrk<Kosilo<Vecerja, Kava<Caj)
Resources (Salica(1), Lonec(1))
Action (Zajtrk, DURATION:10, USE:Salica(1))
Action (Kosilo, DURATION:15)
Action (Vecerja, DURATION:10, USE:Lonec(1))
Action (Kava, DURATION:30, USE:Salica(1))
Action (Caj, DURATION:15, USE:Lonec(1))
```

- (7t) Na zgornjem planu simuliraj *algoritem najmanjše časovne rezerve* (angl. minimum slack algorithm) in z njim določi plan izvajanja (grafično).
- (3t) Ali je algoritem v točki a) našel optimalno rešitev? Če ne, predlagaj boljšo (na pamet, brez simulacije algoritma).


Pregled

III. PLANIRANJE in razporejanje opravil

- predstavitev problema
- planiranje s "klasičnim" preiskovanjem prostora stanj
- planiranje s sredstvi in cilji
- planiranje z regresiranjem ciljev
- razporejanje opravil

IV. VERJETNOSTNO SKLEPANJE z bayesovskimi mrežami

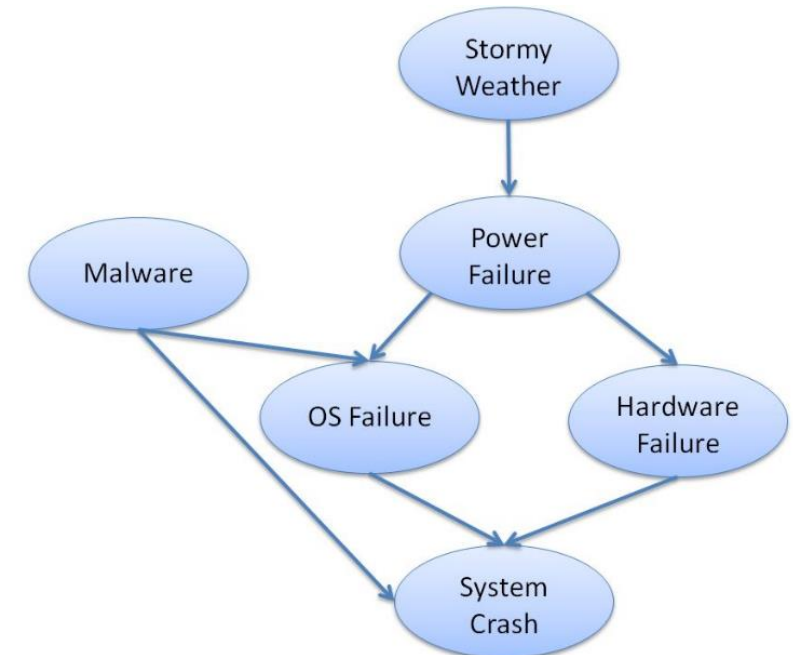
- definicija
- izračun verjetnosti dogodkov
- vprašanja pri verjetnostnem sklepanju
- odvisnosti v bayesovski mreži
- neodvisnosti v bayesovski mreži
- ekvivalenca bayesovskih mrež



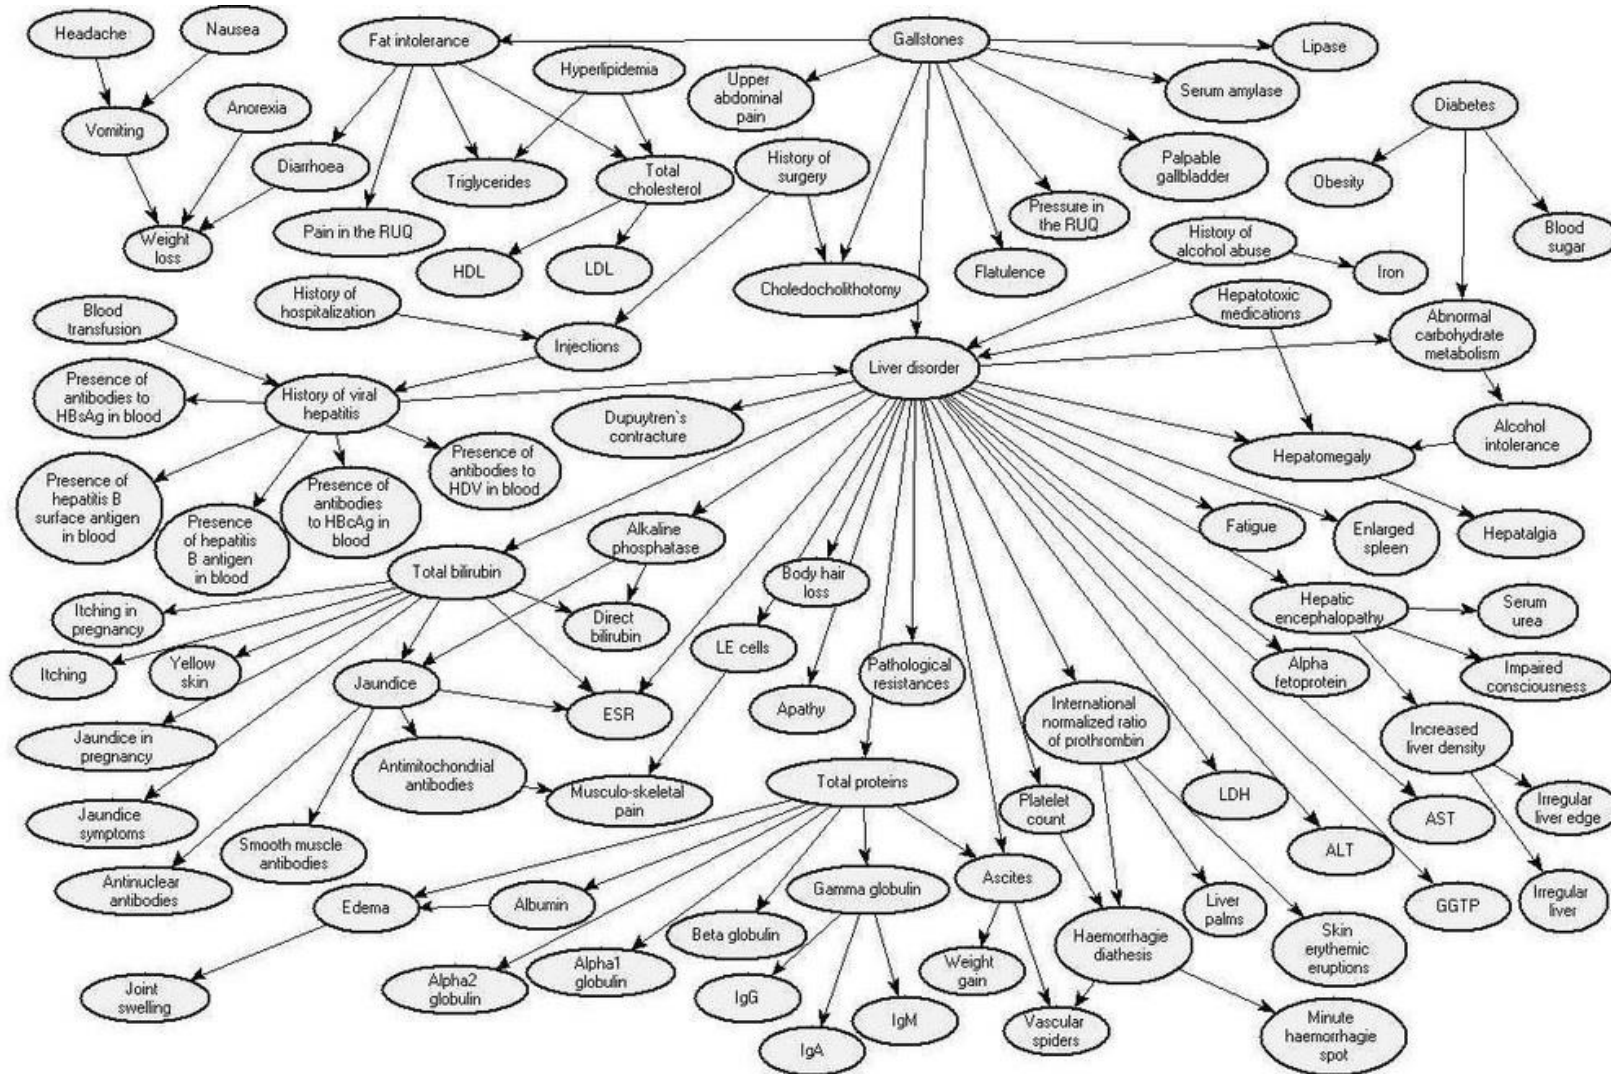
IV. SKLEPANJE

Bayesovske mreže

- so verjetnostni model, s katerim predstavimo **odvisnosti med slučajnimi spremenljivkami**
- pristop za **obravnavo negotovosti** v bazah znanja, ki je matematično dobro utemeljen v verjetnosti
- model je predstavljen z **usmerjenim acikličnim grafom**:
 - **vozlišča**: slučajne spremenljivke (dejstva, hipoteze),
 - **povezave**: odvisnosti med spremenljivkami (vpliv starša na naslednika)
- primeri uporabe:
 - splošno: za **predstavitev verjetnostnega znanja** in **verjetnostno sklepanje**
 - medicina: povezave med boleznijo in simptomi (diagnostika), napovedovanje izida operacije
 - ekspertni sistemi: ocenjevanje kvalitete vode, ...
 - sklepanje: kako verjetno so določene trditve, če vemo, da so druge trditve resnične?




Primer iz medicine



Bayesovske mreže

- stanje sveta povzamemo z **vektorjem (logičnih) spremenljivk**
- inteligentni agent (program) sklepa na **verjetnost** resničnosti določene spremenljivke
- upoštevamo lahko, da so določene spremenljivke med seboj **neodvisne**, kar predstavimo z bayesovsko mrežo, ki odraža te neodvisnosti (nepovezana vozlišča niso odvisna)
- primer:
 - senzor se sproži ob vlomu v hišo
 - včasih lahko tudi udar strele nehoteno sproži senzor
 - senzor ima nalogo, da sproži alarm in izvede opozorilni telefonski klic
- odvisnosti, ki izhajajo iz mreže:
 - senzor je odvisen od vloma in strele
 - alarm je odvisen od senzorja
 - klic je odvisen od senzorja



Bayesovske mreže

- z zapisom $P(X)$ okrajšamo $P(X = \text{true})$, z zapisom $P(XY)$ pa konjunkcijo
- za opis stanja sveta, ki ima n spremenljivk, bi morali poznati **popolno verjetnostno porazdelitev** ($2^n - 1$ podatkov – možnih stanj vseh logičnih spremenljivk)

- spremenljivke: V, St, Se, A, K
- popolna verjetnostna porazdelitev:

$$P(V St Se A K) = \dots$$


$$P(\sim V St Se A K) = \dots$$

$$P(V \sim St Se A K) = \dots$$

$$P(\sim V \sim St Se A K) = \dots$$

...

- potrebujemo $2^5 - 1 = 31$ verjetnosti
- nepraktično ali nemogoče za veliko število spremenljivk



- verjetnost pojubnega dogodka (npr. $P(VK)$) izračunamo z vsoto vseh kombinacij vrednosti spremenljivk St, Se, A (pozitivna ali negirana) pri vrednostih $V = \text{true}$ in $K = \text{true}$.

Pogojne verjetnosti

- ker bayesovska mreža opredeljuje odvisnosti spremenljivk, lahko opredelimo problem samo s **pogojnimi verjetnostmi**:

$$P(vlom) = 0,001$$

$$P(strela) = 0,02$$

$$P(senzor \mid vlom \wedge strela) = 0,9$$

$$P(senzor \mid vlom \wedge \sim strela) = 0,9$$

$$P(senzor \mid \sim vlom \wedge strela) = 0,1$$

$$P(senzor \mid \sim vlom \wedge \sim strela) = 0,001$$


$$P(alarm \mid senzor) = 0,95$$

$$P(alarm \mid \sim senzor) = 0,001$$

$$P(klic \mid senzor) = 0,95$$

$$P(klic \mid \sim senzor) = 0$$

- podamo torej 10 podatkov namesto $2^5 - 1 = 31$
- za spremenljivke, ki niso med seboj odvisne, ne potrebujemo vseh kombinacij verjetnosti:
 - če sta X in Y **odvisna**, v splošnem velja $P(XY) = P(X) \cdot P(Y|X)$
(potrebujemo $P(Y|X)$)
 - če sta X in Y **neodvisna**, velja: $P(XY) = P(X) \cdot P(Y)$
($P(Y|X)$ ne potrebujemo, ker zaradi neodvisnosti velja $P(Y|X) = P(Y)$)



Pogojne verjetnosti

- pogojne verjetnosti lahko predstavimo tudi s tabelami pogojnih verjetnosti

$P(vlom)$
0,001

$P(strela)$
0,02

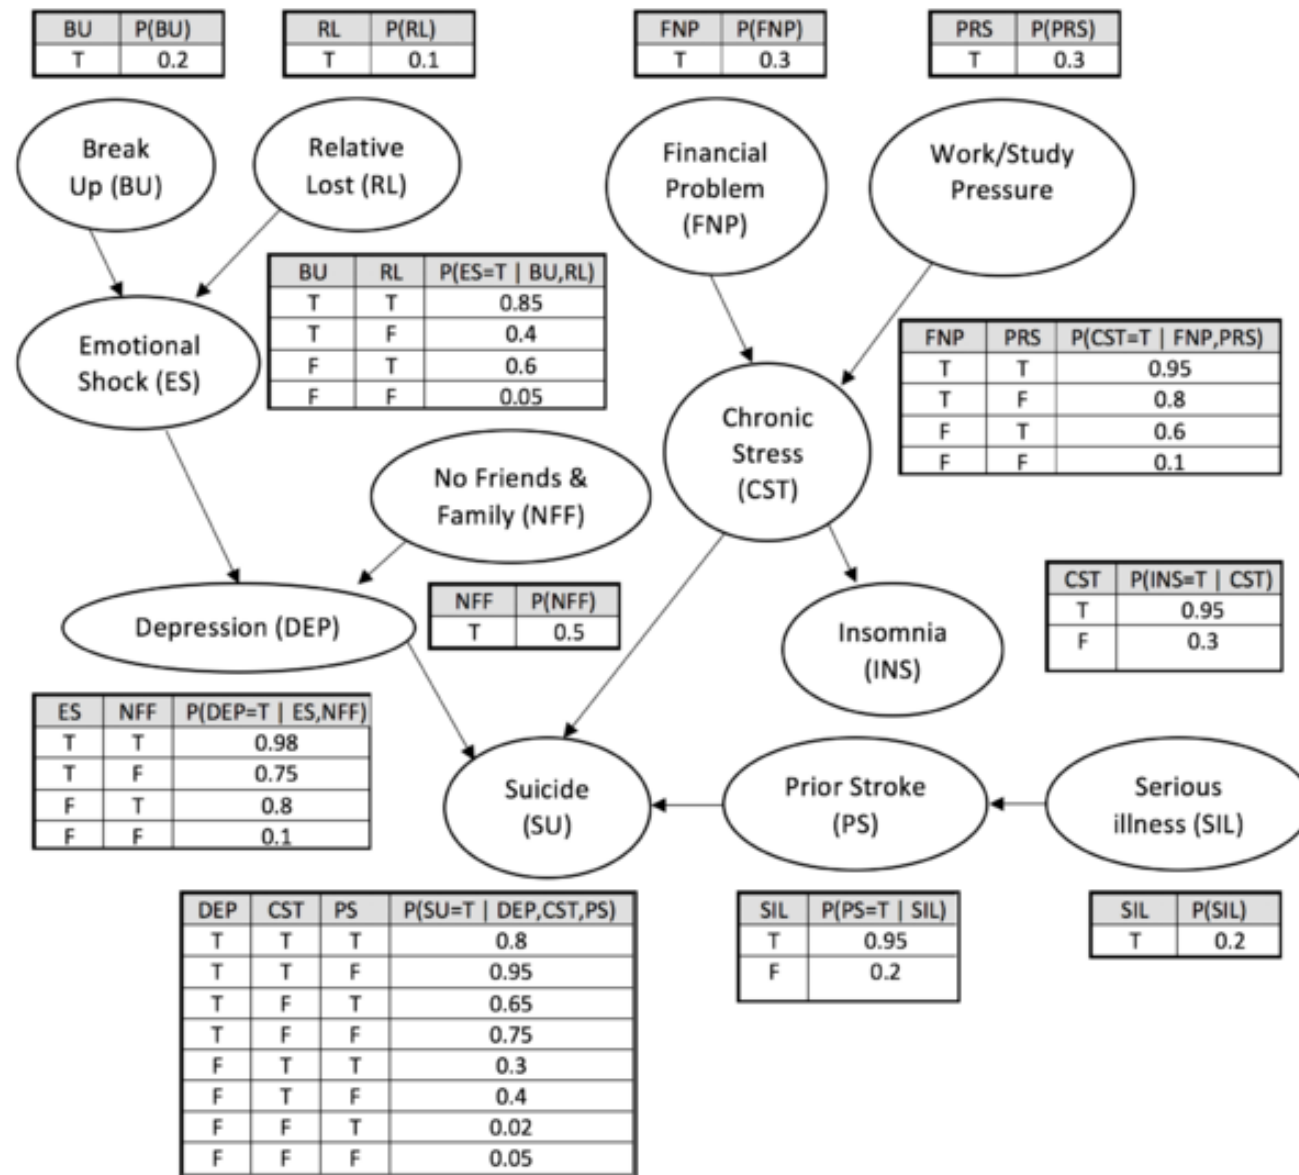
$vlom$	$strela$	$P(senzor)$
true	true	0,9
true	false	0,9
false	true	0,1
false	false	0,001

$senzor$	$P(alarm)$
true	0,95
false	0,001

$senzor$	$P(klic)$
true	0,95
false	0

- verjetnostni značaj modeliranja z bayesovskimi mrežami: podane verjetnosti nakazujejo, da obstajajo za X tudi drugi, neopredeljeni razlogi, ki niso zajeti v predstavitvi problema s podano mrežo (pri modeliranju se omejimo na relevantne vplivne dejavnike = predpostavka zaprtega sveta)

Primer s podanimi verjetnostmi



Izračun verjetnosti dogodka

- s pogojnimi verjetnostmi **preprosteje izračunamo verjetnost dogodka** iz popolne verjetnostne porazdelitve

- primer: kakšna je verjetnost $P(V \sim St \ Se \ A \ K)$?

$$\begin{aligned} P(V \sim St \ Se \ A \ K) &= P(V) \cdot P(\sim St \ Se \ A \ K|V) = \\ &= P(V) \cdot P(\sim St | V) \cdot P(Se | V \sim St) \cdot P(A | V \sim St \ Se) \cdot P(K | V \sim St \ Se \ A) \end{aligned}$$

- zaradi neodvisnosti, podanih v mreži, velja:

$$P(\sim St | V) = P(\sim St)$$

$$P(A | V \sim St \ Se) = P(A | Se)$$

$$P(K | V \sim St \ Se \ A) = P(K | Se)$$

- torej:

$$\begin{aligned} P(V \sim St \ Se \ A \ K) &= P(V) \cdot P(\sim St \ Se \ A \ K|V) = \\ &= P(V) \cdot P(\sim St) \cdot P(Se | V \sim St) \cdot P(A | Se) \cdot P(K | Se) \\ &= 0,001 \cdot 0,98 \cdot 0,9 \cdot 0,95 \cdot 0,9 = 0,00075 \end{aligned}$$

- v splošnem velja:

$$P(X_1 X_2 \dots X_n) = \prod_{i=1}^n P(X_i | \text{starši}(X_i))$$

